

TRABAJO DE FIN DE MÁSTER

Generación de Datos Sintéticos para Sectores Sensibles

Máster Universitario en Inteligencia Artificial

Autor: Marco Fernández Pérez

Universidad: Universidad Alfonso X el Sabio (UAX)

| Índice de la Defensa



Contexto

Problema y
Objetivos



Metodología

Arquitectura
TabDDPM



Resultados

Fidelidad y Utilidad



Privacidad

Cumplimiento Legal
GDPR

Introducción y Contexto Clínico

-  Los **historiales médicos electrónicos** tienen un enorme potencial predictivo.
-  Normativas como el **GDPR** limitan severamente su uso, circulación y explotación.
-  Esto ha provocado la aparición de "**silos de datos**" infranqueables en la investigación sanitaria.



| El Cuello de Botella Operativo

5

Meses de Espera
(Time-to-Data)

- ❌ La **anonimización clásica** (k-anonimato) fracasa ante el cruce con bases de datos externas (Ej. Netflix).
 - 🕒 Enmascarar los datos de forma agresiva **destruye la integridad estadística** y la señal predictiva vital.
-

El Reto del Desbalance Clínico



Objetivo Técnico:

Generar datos sintéticos tabulares que preserven la débil señal de la minoría sin colapsar bajo el peso de la mayoría.

| Objetivos de la Investigación

Sintetizar gemelos de datos tabulares cumpliendo la ley sin degradar utilidad



Arquitectura

Implementar un Modelo Probabilístico de Difusión tabular.



Utilidad

Ejecutar protocolos *Train on Synthetic, Test on Real* (TSTR).



Privacidad

Auditar el riesgo de inferencia ante las normativas GDPR.

Estado del Arte: IA Generativa



Redes GANs

Sufren inestabilidad matemática y *"colapso de modo"* en clases minoritarias.



Autoencoders VAEs

Difuminan excesivamente las fronteras de decisión clínicas por la regularización KL.



Difusión (Propuesta)

Procesos de difusión probabilística pura sin componente competitivo adversarial.

Diseño de la Investigación: El Dataset

Diabetes 130-US Hospitals

Extracto masivo y longitudinal de registros de pacientes ingresados en hospitales estadounidenses.

- ✓ **99.340 registros consolidados** y purgados de valores nulos estructurales.
- 1/2 **39 variables clínicas mixtas** (9 numéricas, 30 categóricas).
- 💊 Incluye demografía, administración hospitalaria y posología farmacológica detallada.

| Arquitectura TabDDPM Propuesta

-  Transformación a vectores latentes de **139 dimensiones** (One-Hot y escalado estándar).
 -  **Planificador de Ruido:** Decaimiento lineal continuo con $T=1000$ pasos temporales.
 -  **Red Denoising:** Perceptrón multicapa con conexiones residuales (>1 millón de parámetros).
-

| Protocolos de Evaluación

2. Utilidad (TSTR)

Entrenamiento sintético ciego y prueba sobre datos reales del mundo real con XGBoost.

1. Fidelidad

Medición de Distancia de Wasserstein y Error Absoluto en Matrices de Correlación.


3. Privacidad

Auditorías empíricas de Memorización (DCR) y simulaciones de Inferencia (MIA).

| Convergencia y Estudio de Ablación

-  **Estabilidad:** Entrenamiento consistente durante 1000 épocas, estabilizando la pérdida (MSE) sin oscilaciones adversariales.
 -  **Planificador Lineal:** Superó radicalmente al planificador de coseno, evitando la destrucción prematura de representaciones categóricas dispersas (One-Hot).
 -  **Fallo del VAE:** El modelo TVAE falló estructuralmente al difuminar las fronteras de la clase minoritaria debido al peso de la divergencia KL.
-

Fidelidad Estadística Marginal




Distancia de Wasserstein Promedio (W1). Menor es mejor.

Alta precisión al modelar distribuciones multimodales y colas largas hospitalarias.

| Preservación de Correlación Multivariante

- ⚡ Diferencia matricial MAE extremadamente baja en TabDDPM: **0.0122**.
 - 🧑 CTGAN (0.0675) sufrió colapso de modo, inventando correlaciones espurias inexistentes.
 - 🔗 El proceso de difusión **conserva íntegramente las reglas lógicas** y de negocio inherentes a la patología.
-

Utilidad Predictiva Operativa (TSTR)



Métrica F1-Score en clasificación XGBoost.

El modelo generativo actúa como Data Augmentation natural para la clase minoritaria crítica.

Auditoría de Privacidad GDPR: Memorización

0.00%

Riesgo de Copia Exacta

- 📄 **Evaluación DCR:** Distancia euclidiana mínima al registro original es siempre estrictamente mayor que cero.
- 📏 Distancia de seguridad mínima establecida en TabDDPM: **0.3938.**
- ✓ El modelo no ha operado memorizando pacientes reales del hospital.

Auditoría de Privacidad GDPR: Inferencia

0.5033

ROC-AUC del Atacante



Ataques MIA neutralizados: La capacidad del atacante para inferir membresía es equivalente al azar puro.



Cumplimiento normativo del Grupo de Trabajo del Artículo 29 certificado.



Los datos generados adquieren la categorización legal de **datos anónimos irreversibles**.

Limitaciones Estructurales Identificadas



Costo Computacional

Inferencia secuencial de Markov en 1000 pasos resulta lenta frente a un simple *forward pass* de redes GAN.



Hardware Dependiente

El entramado matemático exige aceleración masiva por GPU para entrenamiento e inferencia en producción.



Limitación Relacional

Operativa validada sobre una única tabla plana, ignorando el fenómeno clínico longitudinal de *Concept Drift*.

| Impacto Operativo Empresarial

98.4%

Reducción del Time-to-Data



Transición dramática de **5 meses** de procesos burocráticos a menos de **24 horas**.



Coste asimétrico: Fuerte inversión única en el entrenamiento del modelo versus generación masiva lineal en minutos.



Aceleración de los flujos de trabajo en equipos de Ciencia de Datos clínicos.

| Conclusiones y Siguietes Pasos

Solución Validada: La arquitectura democratiza la información sensible, rompiendo el conflicto utilidad-privacidad.



Solvers Rápidos

Implementación de Solvers
Deterministas (DDIM) para
alta velocidad de muestreo.



Grafos Relacionales

Escalado del ecosistema
generativo hacia bases de
datos de integridad
referencial (Multi-Table).



Privacidad (DP)

Integración de Privacidad
Diferencial Formal (DP-SGD)
en el flujo de entrenamiento.

Muchas gracias por su atención

Defensa del Trabajo de Fin de Máster

Marco Fernández Pérez | Universidad Alfonso X el Sabio

Turno abierto para las preguntas del tribunal


Image Sources



<https://media.istockphoto.com/id/2154829989/photo/a-doctor-interacting-with-medical-icons-on-a-futuristic-interfac.jpg?s=612x612&w=0&k=20&c=xsu2w3mao1Xv7T7TiUlvo91RWVBJ-IoqNmtb8n1vQXA=>
Source: www.istockphoto.com



https://ik.imagekit.io/upgrad1/abroad-images/imageCompo/images/ChatGPT_Image_Nov_20_2025_03_47_56_PMTT18DE.png
Source: www.upgrad.com



https://miro.medium.com/1*brq_vvcnVqsOWoVvsjT0pA.png
Source: medium.com
