

UAX

TRABAJO FIN DE MÁSTER

**MUIA
24-25**

UNIVERSIDAD ALFONSO X EL SABIO

Business Tech

Máster Universitario en Inteligencia Artificial



TRABAJO DE FIN DE MÁSTER

**Generación de Datos Sintéticos para Sectores
Sensibles**

Marco, Fernández Pérez

Leonardo Dulcetti

Mayo 2026

RESUMEN

El acceso a historiales médicos electrónicos está severamente limitado por las normativas de privacidad vigentes, como el Reglamento General de Protección de Datos (GDPR). Esta imposibilidad de compartir información frena la innovación en el sector sanitario. Para solventar este bloqueo, este Trabajo de Fin de Máster propone un marco basado en Inteligencia Artificial Generativa diseñado para sintetizar gemelos de datos tabulares clínicos, garantizando el anonimato legal sin sacrificar el valor predictivo original.

A nivel metodológico, se ha diseñado un flujo de trabajo empleando un conjunto de datos médicos reales, caracterizado por un severo desbalanceo de clases y variables mixtas. Se han entrenado y evaluado diversas arquitecturas de estado del arte, haciendo especial hincapié en la adaptación de un modelo probabilístico de difusión al dominio tabular. El rendimiento del ecosistema ha sido auditado mediante métricas de fidelidad estadística y protocolos de validación cruzada para certificar la utilidad predictiva. Además, se han integrado auditorías empíricas rigurosas para cuantificar el riesgo de memorización de pacientes y la resistencia frente a ataques de inferencia de membresía.

Los resultados empíricos demuestran la viabilidad técnica de la arquitectura de difusión progresiva frente a otros paradigmas generativos. Las distribuciones generadas replican fielmente las fronteras de decisión de los datos originales, ofreciendo una paridad predictiva excepcional al entrenar algoritmos externos. Paralelamente, las pruebas de privacidad evidencian que se anulan las vulnerabilidades de reidentificación, situando la probabilidad de éxito de cualquier atacante en niveles de mero azar.

En conclusión, la metodología desarrollada certifica que es posible democratizar los datos sensibles para la investigación. Al satisfacer los estrictos requerimientos de anonimización exigidos por la normativa europea, el sistema permite transformar repositorios restringidos en recursos explotables, reduciendo drásticamente los bloqueos burocráticos y los tiempos de acceso a los datos en proyectos corporativos de inteligencia artificial.

Palabras clave

Inteligencia Artificial Generativa, Datos Tabulares Sintéticos, Modelos de Difusión, Privacidad de Datos, GDPR.

ABSTRACT

Access to electronic medical records is severely limited by current privacy regulations, such as the General Data Protection Regulation (GDPR). This inability to share information hampers innovation in the healthcare sector. To overcome this bottleneck, this Master's Thesis proposes a framework based on Generative Artificial Intelligence designed to synthesize digital twins of clinical tabular data, guaranteeing legal anonymity without sacrificing the original predictive value.

Methodologically, a workflow has been designed using a real medical dataset, characterized by severe class imbalance and mixed variables. Various state-of-the-art architectures have been trained and evaluated, with special emphasis on adapting a denoising diffusion probabilistic model to the tabular domain. The performance of the ecosystem has been audited using statistical fidelity metrics and cross-validation protocols to certify predictive utility. Furthermore, rigorous empirical audits have been integrated to quantify patient memorization risk and resilience against membership inference attacks.

Empirical results demonstrate the technical viability of the progressive diffusion architecture compared to other generative paradigms. The generated distributions faithfully replicate the decision boundaries of the original data, offering exceptional predictive parity when training external algorithms. Concurrently, privacy tests show that re-identification vulnerabilities are nullified, placing any attacker's probability of success at mere chance levels.

In conclusion, the developed methodology certifies that it is possible to democratize sensitive data for research. By satisfying the strict anonymization requirements demanded by European regulations, the system allows transforming restricted repositories into exploitable resources, drastically reducing bureaucratic roadblocks and data access times in artificial intelligence projects.

Keywords

Generative Artificial Intelligence, Synthetic Tabular Data, Diffusion Models, Data Privacy, GDPR.

ÍNDICE

Capítulo 1: Introducción al Trabajo Fin de Máster	8
1. Justificación del proyecto realizado	8
2. Presentación del proyecto y sus contenidos	10
Capítulo 2: Objetivos del TFM	13
1. Objetivo general	13
2. Objetivos específicos	14
Capítulo 3: Marco Teórico / Estado del Arte	17
1. El Paradigma de la Privacidad de Datos en el Sector Clínico	17
1.1 El Reglamento General de Protección de Datos (GDPR)	18
1.2 Antecedentes Históricos: Del k-anonimato a la Síntesis Generativa	18
1.3 Anonimización y el Dictamen del Grupo de Trabajo del Artículo 29	20
1.4 Privacidad Empírica vs. Privacidad Diferencial Formal	21
1.5 Modelos de Riesgo: Memorización e Inferencia de Mem- bresía	22
2. Evolución del Modelado Generativo Profundo	23
2.1 Redes Generativas Antagónicas (GANs)	23
2.2 Adaptaciones de las GANs al Dominio Tabular y sus Li- mitaciones	24
2.3 Autoencoders Variacionales (VAEs)	25
3. Modelos Probabilísticos de Difusión (Denoising Diffusion)	27
3.1 Fundamentos Matemáticos: Cadenas de Markov y Proce- so Forward	27
3.2 El Proceso Inverso y el Aprendizaje de Denoising	28
3.3 Adaptación al Dominio Tabular: El Framework TabDDPM	29
4. El Ecosistema de Evaluación de Datos Tabulares Sintéticos	30
4.1 Fidelidad Estadística: La Distancia de Wasserstein	30
4.2 Utilidad Predictiva: El Paradigma TSTR frente a TRTR	31

4.3	Privacidad Empírica: DCR y MIA como Vectores de Auditoría	32
Capítulo 4: Marco Metodológico		34
1.	Infraestructura y Entorno de Ejecución	34
2.	Origen de Datos y Análisis Exploratorio	35
2.1	El Conjunto de Datos Clínico	35
2.2	El Desafío del Desbalanceo y el Objetivo Predictivo	36
2.3	Ingeniería de Características y Limpieza	37
2.4	Descripción del Espacio de Variables Consolidado	37
2.5	Análisis Exploratorio Cuantitativo	39
3.	Desarrollo e Implementación de Modelos Generativos	40
3.1	Línea Base Adversarial: CTGAN	40
3.2	Línea Base Bayesiana: TVAE	41
3.3	Arquitectura Propuesta: TabDDPM	41
4.	Diseño de Protocolos de Evaluación y Auditoría	43
4.1	Protocolo TSTR (Train on Synthetic, Test on Real)	44
4.2	Medición de Fidelidad: Distancia Multivariante	44
4.3	Auditorías de Privacidad (GDPR)	45
Capítulo 5: Análisis y Resultados		46
1.	Convergencia del Entrenamiento: Análisis de la Curva de Pérdida	46
2.	Fidelidad Estadística y Preservación Estructural	47
2.1	Distancia de Wasserstein por Variable	48
2.2	Análisis de la Estructura de Correlación Multivariante	49
3.	Utilidad Predictiva: Evaluación TSTR	51
4.	Estudio de Ablación Intra-Arquitectónico	52
4.1	Ablación sobre TabDDPM: Impacto del Schedule y los Pasos de Difusión	52
4.2	Ablación sobre TVAE: Análisis de la Limitación Estructural	53
5.	Auditoría Legal y Privacidad Empírica (GDPR)	55
5.1	Distancia de Riesgo de Memorización (DCR)	55
5.2	Ataques Adversariales de Inferencia de Membresía (MIA)	56
6.	Impacto Empresarial: Análisis del Time-to-Data	57
6.1	Reducción del Time-to-Data	57
6.2	Viabilidad de Despliegue Corporativo y Escalabilidad MLOps	59
Capítulo 6: Conclusiones		60
7.	Síntesis Comparativa de Resultados	60

1.	Consecución de los Objetivos	60
2.	Consideraciones Finales y Reflexión Personal	62
3.	Limitaciones del Estudio	64
4.	Prospectiva y Trabajo Futuro	65
5.	Consideraciones Finales y Reflexión Personal	66
Bibliografía		68
Anexos		72
A.1.	Diccionario de Hiperparámetros de Entrenamiento	72
A.2.	Repositorio de Código Fuente	72

Capítulo 1: Introducción al Trabajo Fin de Máster

La era de la digitalización ha transformado radicalmente todos los sectores de la sociedad moderna, pero pocos han experimentado un cambio tan profundo y con tanto potencial como el sector sociosanitario. La adopción masiva de los Historiales Médicos Electrónicos (EHR, por sus siglas en inglés) ha generado repositorios de información de un valor incalculable. Estos conjuntos de datos masivos encierran patrones ocultos que, mediante la aplicación de técnicas avanzadas de Inteligencia Artificial (IA) y Aprendizaje Automático (Machine Learning), pueden revolucionar la medicina preventiva, optimizar los diagnósticos, personalizar los tratamientos y, en última instancia, salvar vidas y reducir drásticamente los costes operativos de los sistemas de salud públicos y privados. Sin embargo, el aprovechamiento real de estos datos se enfrenta a un desafío técnico y regulatorio complejo: la privacidad.

En este capítulo introductorio se establecen las bases fundamentales que motivan la realización de este Trabajo de Fin de Máster. En primer lugar, se justificará la necesidad imperante de desarrollar nuevas tecnologías que permitan eludir la actual dicotomía entre la utilidad de los datos médicos y el derecho a la privacidad de los pacientes. Posteriormente, se presentará formalmente el proyecto, detallando el problema técnico que se aborda, la solución propuesta basada en Inteligencia Artificial Generativa y, finalmente, se desglosará la estructura de los contenidos que conforman la presente memoria académica.

1. Justificación del proyecto realizado

El siglo XXI ha sido testigo de un crecimiento exponencial en la capacidad de computación y en el desarrollo de algoritmos de Inteligencia Artificial. No obstante, el combustible que alimenta estos algoritmos son los datos. En el ámbito

clínico, los datos son intrínsecamente sensibles, ya que contienen Información de Identificación Personal (PII) y datos médicos altamente confidenciales. En respuesta a los crecientes riesgos de ciberseguridad y abusos corporativos, legislaciones como el Reglamento General de Protección de Datos (GDPR) en la Unión Europea o la ley HIPAA en Estados Unidos han establecido marcos normativos extremadamente estrictos para proteger a los ciudadanos.

Estas normativas, aunque éticamente inobjetables y absolutamente necesarias, han generado un efecto colateral conocido como “silos de datos”. Las instituciones hospitalarias, los centros de investigación y las empresas de tecnología sanitaria se encuentran frecuentemente paralizadas por el miedo a incurrir en infracciones legales que conllevan sanciones económicas devastadoras y un daño reputacional irreparable. En el entorno corporativo y académico actual, el proceso burocrático para acceder a un conjunto de datos clínicos reales que involucra aprobaciones de comités de ética, revisiones del Delegado de Protección de Datos (DPO) y firmas de Acuerdos de Confidencialidad (NDA) puede demorarse entre tres y cinco meses (de 9 a 18 semanas). Esta métrica, conocida en la industria como *Time-to-Data*, es actualmente el mayor cuello de botella para la innovación en salud digital.

Históricamente, la solución a este problema ha sido la anonimización tradicional, consistente en la supresión de identificadores directos (nombres, documentos de identidad) y la generalización de identificadores indirectos (códigos postales, edades). Sin embargo, la literatura científica ha demostrado reiteradamente que estas técnicas son ineficaces. Ataques de reidentificación cruzando bases de datos aparentemente anónimas con información pública (como padrones electorales o redes sociales) han logrado desenmascarar a pacientes con un éxito alarmante. Por otro lado, aplicar técnicas de enmascaramiento agresivas destruye la integridad estadística del dataset; se pierde la correlación multivariante y la señal predictiva, volviendo los datos inútiles para el entrenamiento de modelos de Machine Learning. Existe, por tanto, un “tira y afloja” insalvable entre privacidad y utilidad.

Es en este contexto de necesidad clínica y restricción legal donde surge la justificación primordial de este proyecto: el uso de Inteligencia Artificial Generativa para la síntesis de datos. A diferencia de la anonimización, que toma un paciente real y oculta sus rasgos, la síntesis de datos genera “pacientes vir-

tuales” desde cero. Estos pacientes virtuales no existen en el mundo real, pero exhiben exactamente las mismas propiedades matemáticas, estadísticas y predictivas que la población original. Al ser datos generados artificialmente que no corresponden a ningún individuo de carne y hueso, eluden las restricciones del GDPR, permitiendo su libre circulación para la investigación científica.

A nivel de motivación técnica y profesional, este proyecto se adentra en la frontera más avanzada del Deep Learning. Mientras que la generación de imágenes o texto natural ha alcanzado niveles de madurez asombrosos (con modelos como DALL-E o GPT), la generación de datos tabulares (filas y columnas, variables continuas y categóricas) sigue siendo un desafío abierto en la comunidad científica. Los datos tabulares carecen de la estructura espacial de una imagen o la estructura secuencial de un texto; presentan distribuciones multimodales, dependencias complejas y, frecuentemente, desbalances de clases extremos. La motivación técnica de este Trabajo de Fin de Máster es superar estos obstáculos implementando la tecnología más puntera: los Modelos Probabilísticos de Difusión (Diffusion Models), adaptándolos para operar sobre arquitecturas de datos tabulares y evaluando si logran desbancar a las aproximaciones previas basadas en Redes Generativas Antagónicas (GANs) y Autoencoders Variacionales (VAEs).

2. Presentación del proyecto y sus contenidos

Este Trabajo de Fin de Máster propone el desarrollo, implementación y evaluación exhaustiva de un marco tecnológico (*framework*) de generación de datos sintéticos diseñado específicamente para entornos clínicos de alta sensibilidad. El núcleo del proyecto radica en la construcción algorítmica desde cero de un Modelo Probabilístico de Difusión y su contraste empírico frente a arquitecturas generativas de referencia en el estado del arte.

El problema técnico sobre el que pivotará la experimentación empírica es la predicción de una patología en un conjunto de pacientes, un clásico problema de clasificación caracterizado por un severo desbalanceo de clases (donde la clase minoritaria de interés representa una fracción muy pequeña de los datos reales). Este escenario es el entorno de prueba ideal, ya que sintetizar datos

que logren preservar la débil señal de la clase minoritaria es la prueba de fuego de cualquier modelo generativo.

El proyecto no se limita meramente a la construcción matemática del algoritmo, sino que aborda la problemática desde una perspectiva holística de Ingeniería de Datos y Operaciones de Machine Learning (MLOps). Para ello, se ha diseñado un *pipeline* de evaluación tridimensional que somete a los datos generados a auditorías de:

- **Fidelidad Estadística:** Para demostrar que las distribuciones y correlaciones marginales son estadísticamente indistinguibles de la realidad.
- **Utilidad Predictiva:** Para certificar que un algoritmo externo de Inteligencia Artificial, entrenado exclusivamente con los datos sintéticos, mantiene su precisión al ser desplegado en un entorno de pruebas real.
- **Privacidad Empírica:** Para auditar matemáticamente los riesgos de memorización o inferencia, asegurando que los datos virtuales no constituyen una amenaza para la privacidad del conjunto de entrenamiento y cumplen con las directrices legales.

Para abordar esta compleja labor investigativa de manera ordenada y académica, la presente memoria se ha estructurado en seis capítulos principales.

El presente **Capítulo 1** ha introducido el contexto, la motivación y la presentación general del problema abordado.

El **Capítulo 2** detallará formalmente el objetivo general del Trabajo de Fin de Máster, así como los objetivos específicos que actúan como hitos secuenciales para su consecución.

El **Capítulo 3** conformará el Marco Teórico y el Estado del Arte. En esta sección se realizará una inmersión profunda en la literatura científica, abordando las fundamentaciones matemáticas de los distintos modelos generativos, las definiciones teóricas de la privacidad de datos y el contexto regulatorio vigen-

te.

El **Capítulo 4** describirá el Marco Metodológico. Se expondrá con un elevado nivel de detalle técnico el flujo de trabajo ejecutado, desde la exploración inicial y preprocesamiento de la muestra clínica, hasta la arquitectura interna de las redes neuronales desarrolladas y las métricas formales utilizadas en el ecosistema de evaluación tridimensional.

El **Capítulo 5** albergará el núcleo empírico del proyecto: la Presentación de Análisis, Resultados y Discusión. En este capítulo se volcarán todas las métricas, gráficas y tablas de rendimiento, comparando la eficacia de la tecnología de difusión frente a los modelos clásicos, explicando los fenómenos estadísticos detectados, realizando estudios de ablación sobre los componentes de la red y calculando el impacto final en el entorno corporativo.

Finalmente, el **Capítulo 6** presentará las Conclusiones del estudio, donde se verificará el cumplimiento de los objetivos iniciales, se expondrán las limitaciones encontradas durante el desarrollo técnico y se propondrán líneas de investigación prospectivas, cerrando la memoria con una reflexión crítica sobre el proceso de aprendizaje adquirido y las competencias desarrolladas a lo largo del Máster.

Capítulo 2: Objetivos del TFM

Este capítulo establece los objetivos formalmente definidos para el presente Trabajo de Fin de Máster. Se presenta el objetivo general, que sintetiza el propósito de la investigación, y se desglosa secuencialmente en los objetivos específicos que guiarán las fases de estudio teórico, diseño metodológico, implementación técnica, evaluación y auditoría de privacidad.

1. Objetivo general

El objetivo general que vertebra y da sentido a toda la labor investigativa y de desarrollo de este Trabajo de Fin de Máster se enuncia a continuación:

- **Desarrollar y evaluar empíricamente un ecosistema basado en Inteligencia Artificial Generativa capaz de sintetizar gemelos de datos tabulares clínicos que certifiquen el cumplimiento legal de privacidad sin degradar la utilidad predictiva subyacente.**

Para comprender la magnitud y el alcance de este objetivo general, es preciso realizar varias puntualizaciones. El verbo rector elegido es “desarrollar”, lo que implica que este proyecto no se limita a un mero ejercicio de revisión bibliográfica o a la utilización pasiva de herramientas de terceros preexistentes. Por el contrario, exige un esfuerzo constructivo de ingeniería de software, centrado en la implementación algorítmica y la orquestación de un *pipeline* completo de Operaciones de Machine Learning (MLOps).

Asimismo, la mención explícita a la evaluación empírica subraya el carácter

científico de la propuesta; no basta con generar un modelo funcional, sino que es estrictamente necesario someter sus resultados a auditorías matemáticas rigurosas. La finalidad última no es otra que demostrar que es posible quebrar el histórico paradigma que obliga a elegir entre proteger la identidad del paciente o aprovechar el valor estadístico de su información. El éxito de este objetivo general proporcionará un marco tecnológico listo para ser integrado en entornos corporativos, logrando minimizar el *Time-to-Data* y habilitando un escenario de investigación médica segura y ágil.

2. Objetivos específicos

Para garantizar la consecución sistemática y ordenada del objetivo general expuesto, el proyecto de investigación se ha subdividido y estructurado en cinco objetivos específicos. Cada uno de estos objetivos aborda una fase metodológica crítica, desde la fundamentación teórica hasta la validación del producto final.

1. Consolidar el estado del arte respecto a las arquitecturas generativas y los marcos normativos de privacidad de datos.

Antes de acometer cualquier desarrollo, resulta indispensable mapear la literatura científica actual. Este objetivo implica investigar en profundidad las matemáticas subyacentes de las Redes Generativas Antagónicas (GANs), los Autoencoders Variacionales (VAEs) y, especialmente, la vanguardia de los Modelos Probabilísticos de Difusión. Simultáneamente, requiere analizar exhaustivamente el Reglamento General de Protección de Datos (GDPR) y los dictámenes del Grupo de Trabajo del Artículo 29 para definir legalmente qué constituye un dato verdaderamente anónimo.

2. Diseñar un flujo de preprocesamiento e ingeniería de características adaptado a entornos clínicos de alta dimensionalidad.

Los historiales médicos electrónicos en su forma cruda son incompatibles con los tensores de entrada requeridos por las redes neuronales profundas. Este objetivo se enfoca en la purga de inconsistencias lógicas, el tratamiento de valores ausentes estructurales, la reducción de la car-

dinalidad en codificaciones clínicas y la estandarización de espacios continuos y discretos. Resulta vital en esta etapa formular una estrategia robusta para lidiar con el severo desbalanceo de clases que caracteriza a la predicción de patologías poco frecuentes.

3. Implementar y optimizar una arquitectura generativa basada en procesos de difusión probabilística para el dominio tabular.

Este constituye el núcleo ingenieril del proyecto. El objetivo es implementar de forma nativa un algoritmo capaz de destruir la información clínica mediante cadenas de Markov controladas (adición progresiva de ruido gaussiano) y, subsiguientemente, entrenar una red neuronal de *Denoising* para revertir este proceso. El hito técnico consiste en lograr que este modelo converja en un espacio latente mixto (numérico y categórico), superando las limitaciones arquitectónicas tradicionales que sufren otros enfoques generativos.

4. Diseñar un protocolo de evaluación bidimensional para auditar la fidelidad estadística y la utilidad predictiva de los gemelos sintéticos.

La generación de datos carece de valor si no puede cuantificarse su realismo. Para cumplir este objetivo, se deben establecer métricas matemáticas precisas (como la Distancia de Wasserstein y la Diferencia de Matrices de Correlación MAE) que certifiquen la preservación de las distribuciones marginales bivariantes. En paralelo, se debe ejecutar el paradigma TSTR (*Train on Synthetic, Test on Real*), entrenando algoritmos supervisados externos exclusivamente con datos virtuales para certificar empíricamente su rendimiento y paridad en el mundo real.

5. Ejecutar auditorías de privacidad empírica para cuantificar la vulnerabilidad frente a vectores de ataque conocidos.

El último objetivo específico asegura la viabilidad legal y ética del ecosistema desarrollado. Se requiere calcular el Riesgo de Memorización determinando la distancia euclídea del registro sintético más cercano a cualquier registro original (Métrica DCR). Además, se deben orquestar simulaciones de Ataques de Inferencia de Membresía (MIA), entrenando modelos adversarios que intenten deducir si un paciente específico pertenecía al conjunto de datos de entrenamiento, garantizando que su probabilidad de éxito no sea estadísticamente superior a una selección

aleatoria.

Capítulo 3: Marco Teórico / Estado del Arte

El desarrollo de soluciones basadas en Inteligencia Artificial (IA) para la síntesis de datos clínicos no puede entenderse como un esfuerzo puramente algorítmico; se trata de una convergencia multidisciplinar que entrelaza la criptografía, la estadística bayesiana, el aprendizaje profundo y el derecho tecnológico. En este capítulo se establece el marco teórico y se revisa el estado del arte de las tecnologías e investigaciones que fundamentan el presente Trabajo de Fin de Máster.

El capítulo se ha estructurado en cuatro grandes bloques lógicos. En la primera sección se analiza el paradigma de la privacidad de datos, disecando el marco normativo europeo y los criterios legales que definen la anonimización. La segunda sección traza un recorrido evolutivo por las arquitecturas de Deep Learning generativo clásico, analizando rigurosamente las Redes Generativas Antagónicas (GANs) y los Autoencoders Variacionales (VAEs). La tercera sección aborda la vanguardia tecnológica: los Modelos Probabilísticos de Difusión (Diffusion Models) y su reciente adaptación al ecosistema de los datos tabulares. Finalmente, la cuarta sección consolida los protocolos formales de evaluación matemática requeridos para cuantificar la fidelidad, la utilidad y la seguridad de los gemelos digitales generados.

1. El Paradigma de la Privacidad de Datos en el Sector Clínico

La proliferación de los sistemas de información hospitalarios ha generado vastos repositorios de datos masivos. Sin embargo, el historial clínico de un paciente no es meramente un conjunto de variables estadísticas; constituye una proyección digital íntima de su salud, genética y vulnerabilidades. La fuga, explotación o reidentificación indebida de estos datos puede originar conse-

cuencias devastadoras, desde la discriminación en la concesión de seguros de salud y oportunidades laborales, hasta el fraude de identidad y la extorsión.

1.1. El Reglamento General de Protección de Datos (GDPR)

A nivel europeo, la protección de la información ciudadana está regida por el Reglamento (UE) 2016/679, universalmente conocido como el Reglamento General de Protección de Datos (Parlamento Europeo and Consejo de la Unión Europea, 2016). El GDPR establece un marco punitivo y regulatorio sumamente estricto para el manejo de Información de Identificación Personal (PII, por sus siglas en inglés). En el contexto médico, los historiales clínicos son catalogados como “categorías especiales de datos personales” (Artículo 9 del GDPR), lo cual prohíbe explícitamente su tratamiento y distribución generalizada salvo en circunstancias de consentimiento explícito o interés público ineludible.

Esta severidad regulatoria ha paralizado intrínsecamente la colaboración en el ecosistema científico. Las instituciones de investigación se topan con el denominado *Time-to-Data*, un periodo burocrático de meses requerido para tramitar Acuerdos de Procesamiento de Datos, superar Comités Éticos y evaluar el Impacto en la Privacidad (DPIA). Para mitigar este cuello de botella, el propio GDPR proporciona una vía de escape: si los datos son rigurosamente “anónimos”, dejan de estar bajo la jurisdicción del reglamento, permitiendo su libre procesamiento.

1.2. Antecedentes Históricos: Del k-anonimato a la Síntesis Generativa

Antes de que la Inteligencia Artificial Generativa se afanzara como la solución técnica preferente, la comunidad científica desplegó una amplia batería de técnicas estadísticas clásicas para intentar cumplir con los requisitos de

anonimización. Un análisis crítico de sus limitaciones es indispensable para contextualizar la necesidad del enfoque adoptado en el presente trabajo.

El Modelo de k-anonimato. La primera propuesta sistemática y formal fue el *k-anonimato*, introducido por Sweeney (2002). Bajo este paradigma, un conjunto de datos satisface el k-anonimato si cada registro es indistinguible de al menos $k - 1$ registros adicionales con respecto a los denominados *quasi-identificadores* (atributos como la edad, el código postal o el género que, individualmente, son inofensivos pero que combinados pueden singularizar a un individuo). Formalmente, para un conjunto de datos D y un subconjunto de atributos QI , la condición de k-anonimato exige que:

$$\forall r \in D, |\{s \in D \mid s[QI] = r[QI]\}| \geq k$$

Para alcanzar esta propiedad, se aplican técnicas de *supresión* (eliminación de registros que no pueden generalizarse) o *generalización* (sustitución de valores precisos por rangos, como reemplazar la edad “34” por el intervalo “[30-40]”). A pesar de su elegancia conceptual, el k-anonimato adolece de dos vulnerabilidades críticas: los **ataques de homogeneidad**, donde todos los registros del grupo k comparten el mismo valor sensible (haciendo trivial la inferencia), y los **ataques de conocimiento previo**, donde el adversario conoce datos contextuales sobre el individuo objetivo que le permiten reidentificarlo incluso dentro de un grupo de k registros aparentemente equivalentes.

La l-diversidad como extensión. Para subsanar la vulnerabilidad ante los ataques de homogeneidad, Machanavajjhala et al. (2007) propusieron el modelo de *l-diversidad*. Este criterio extiende el k-anonimato exigiendo que cada grupo de k registros equivalentes contenga al menos l valores “bien representados” del atributo sensible. A pesar de que la l-diversidad mitiga los ataques de homogeneidad, introducen sus propias debilidades: el **ataque de similitud**, operativo cuando los l valores distintos del atributo sensible son semánticamente próximos (por ejemplo, tres tipos diferentes de enfermedad renal seguirían revelando información médica crítica); y la dificultad computacional de alcanzar la l-diversidad en conjuntos de datos de alta dimensionalidad sin destruir su integridad estadística.

El colapso empírico de la anonimización estadística. La limitación más devastadora de todos los enfoques clásicos no fue teórica, sino empírica. En

un experimento seminal, Narayanan y Shmatikov (2008) demostraron que el conjunto de datos de valoraciones de películas de Netflix, publicado como supuestamente anónimo, podía ser reidentificado de forma automatizada cruzándolo con valoraciones públicas disponibles en la plataforma IMDb. Aprovechando únicamente un subconjunto mínimo de valoraciones temporalmente vinculadas, los autores lograron desanonimizar registros de usuarios concretos con una alta tasa de éxito. Este experimento reveló una verdad incómoda: la anonimización estadística que opera sobre datos reales mediante supresión o generalización es intrínsecamente frágil frente a la disponibilidad creciente de datos auxiliares externos. Cuanto mayor es la dimensionalidad del dataset original, mayor es el vector de ataque disponible para el adversario.

La confluencia de estas limitaciones fundamentales establece la motivación tecnológica central de este proyecto: la necesidad de un paradigma radicalmente diferente que no opere transformando datos reales existentes, sino generando datos sintéticos desde cero mediante modelos probabilísticos aprendidos. Esta distinción conceptual es la que otorga a la Inteligencia Artificial Generativa su superioridad estructural sobre los enfoques de anonimización clásica.

1.3. Anonimización y el Dictamen del Grupo de Trabajo del Artículo 29

El concepto de anonimización es frecuentemente malinterpretado en la industria tecnológica. Tradicionalmente, se ha creído que la supresión de identificadores directos (nombres, números de seguridad social) o la seudonimización mediante *hashing* criptográfico bastaba para anonimizar una base de datos. La literatura de ciberseguridad ha refutado reiteradamente esta falacia, demostrando que atributos demográficos aparentemente inofensivos (como el código postal, el género y la fecha de nacimiento) son suficientes para reidentificar a un alto porcentaje de la población al cruzarlos con bases de datos externas.

Para arrojar luz legal sobre este conflicto tecnológico, el Grupo de Trabajo del Artículo 29 (el órgano consultivo independiente de la Unión Europea sobre

protección de datos) emitió el Dictamen 05/2014 sobre técnicas de anonimización (Article 29 Data Protection Working Party, 2014). En este documento fundacional, se dictamina que, para considerar un conjunto de datos como legítimamente anónimo, el proceso de transformación debe ser irreversible y garantizar la mitigación de tres riesgos fundamentales:

- **Individualización (Singling out):** La imposibilidad de aislar a un individuo u obtener un registro único a partir de la masa de datos.
- **Vinculación (Linkability):** La incapacidad de relacionar dos o más registros relativos al mismo sujeto en bases de datos dispares.
- **Inferencia (Inference):** La inviabilidad de deducir, con una probabilidad significativa, el valor de un atributo sensible de un individuo a partir de la información proporcionada.

Cualquier metodología de síntesis de datos clínicos debe, por tanto, someterse a auditorías que demuestren el cumplimiento de estos tres criterios para obtener la inmunidad legal que otorga el GDPR.

1.4. Privacidad Empírica vs. Privacidad Diferencial Formal

Para garantizar la mitigación de los riesgos de inferencia expuestos, la comunidad científica ha desarrollado dos vertientes fundamentales de protección: la Privacidad Diferencial Formal y la Privacidad Empírica.

La Privacidad Diferencial (Differential Privacy o DP), propuesta por Dwork (2006), ofrece una garantía matemática inquebrantable. Un algoritmo se considera ϵ -diferencialmente privado si la eliminación o adición de un único individuo en la base de datos de entrenamiento no altera la distribución de probabilidad de la salida del algoritmo más allá de un factor multiplicativo determinado por el presupuesto de privacidad ϵ . Esta técnica se aplica inyectando

ruido estadístico calibrado (mediante mecanismos de Laplace o Gaussianos) durante el entrenamiento de las redes generativas. Sin embargo, como apuntan El Emam et al. (2020), forzar garantías teóricas rígidas en modelos de *Deep Learning* genera una drástica degradación en la fidelidad y utilidad predictiva de los datos resultantes, arruinando su viabilidad corporativa.

Como alternativa, ha surgido el paradigma de la Privacidad Empírica (Stadler et al., 2022). Bajo este enfoque, no se inyecta ruido matemático a ciegas, sino que se entrena el modelo de IA a su máxima capacidad de fidelidad y, a posteriori, se ejecuta una batería de ciberataques simulados contra el modelo y sus datos resultantes. Si los atacantes algorítmicos fracasan en reidentificar a los pacientes, el riesgo se considera “no razonablemente probable”, cumpliendo *de facto* con el considerando 26 del GDPR sin sacrificar la calidad estadística.

1.5. Modelos de Riesgo: Memorización e Inferencia de Membresía

Dentro de la validación de la Privacidad Empírica, los modelos generativos son auditados frente a dos vulnerabilidades críticas. En primer lugar, la **Memorización**, cuantificada habitualmente mediante la métrica *Distance to Closest Record* (DCR). Dado que las redes neuronales masivas tienen millones de parámetros, existe el riesgo inherente de que el modelo sobreajuste (overfitting) y literalmente “memorice” pacientes del set de entrenamiento, escupiéndolos de forma idéntica durante la fase de generación sintética. Un análisis DCR mide la distancia euclidiana entre el clon sintético más cercano y el paciente real original, debiendo garantizar que la distancia sea estrictamente superior a cero en todo el corpus.

En segundo lugar, se encuentra el **Ataque de Inferencia de Membresía (MIA)**. Formalizado matemáticamente por Shokri et al. (2017), un MIA es un vector de ataque en el que un actor malicioso entrena un modelo clasificador binario en la sombra. El objetivo de este clasificador no es otro que predecir si un paciente específico en la vida real formó parte (membresía) del grupo de datos original con el que se entrenó la Inteligencia Artificial. Un modelo

generativo robusto mitigará este ataque, forzando a la red del adversario a operar con una curva ROC-AUC cercana a 0.50, equivalente estadísticamente al lanzamiento de una moneda al azar.

2. Evolución del Modelado Generativo Profundo

La Inteligencia Artificial Generativa ha transitado por una evolución vertiginosa durante la última década. El objetivo fundamental de esta rama del Aprendizaje Automático no es discriminar o clasificar datos preexistentes, sino aprender la distribución de probabilidad subyacente $p_{data}(x)$ de un conjunto de datos reales, de modo que el modelo pueda generar nuevas muestras extraídas de una distribución aproximada $p_{model}(x)$.

2.1. Redes Generativas Antagónicas (GANs)

El punto de inflexión en la IA Generativa contemporánea aconteció en 2014 con la formulación de las Redes Generativas Antagónicas (GANs) por Goodfellow et al. (2014). El marco de trabajo de las GANs se fundamenta en la Teoría de Juegos, proponiendo una arquitectura compuesta por dos redes neuronales que compiten en un juego minimax de suma cero: el Generador (G) y el Discriminador (D).

El Generador ingiere ruido aleatorio z procedente de un espacio latente estructurado (usualmente una distribución gaussiana normalizada) y lo transforma en un vector $G(z)$ con el objetivo de imitar los datos reales. Por su parte, el Discriminador actúa como un clasificador binario que recibe una mezcla de datos reales x y datos falsificados $G(z)$, con el mandato de predecir la autenticidad de cada muestra. La función de pérdida (loss function) que rige este enfrentamiento adversarial se define algebraicamente como:

$$\min_G \max_D V(D, G) = \mathbf{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbf{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$

A medida que el entrenamiento avanza, el Generador se ve forzado a producir falsificaciones cada vez más indetectables, obligando al Discriminador a refinar sus heurísticas de detección. En el límite teórico, el Generador domina la distribución real y el Discriminador es incapaz de decidir ($D = 0,5$).




Figura 1: Arquitectura general y flujo adversarial de una red GAN (ResearchGate, 2019).

2.2. Adaptaciones de las GANs al Dominio Tabular y sus Limitaciones

A pesar de su impacto en la generación de imágenes y texto, la traslación de las GANs al dominio tabular médico presentó desafíos arquitectónicos significativos que motivaron una larga cadena de propuestas especializadas. A diferencia de los píxeles de una imagen, los datos tabulares combinan variables de naturaleza radicalmente heterogénea: valores continuos con distribuciones multimodales (como el número de procedimientos médicos), identificadores discretos ordinales (categorías de edad) y variables nominales de alta cardinalidad (como los 700 códigos diagnósticos ICD-9 originales).

Las primeras adaptaciones al dominio de la salud, como **MedGAN** (Choi et al., 2017), emplearon autoencoders como preprocesadores para comprimir el espacio categórico antes de alimentar al Generador, mitigando parcialmente la incompatibilidad con el ruido gaussiano. Posteriormente, Xu et al. (2019) propusieron **CTGAN** (*Conditional Tabular GAN*), que introdujo dos innovaciones decisivas: un preprocesamiento de Normalización de Modo-Específico mediante mezclas de Gaussianas (VGM) para modelar las distribuciones multimodales, y un mecanismo de muestreo condicional que obliga al Generador

a producir ejemplos equilibrados de cada categoría, aliviando el problema del desbalanceo de clases. Propuestas más recientes como **CTAB-GAN** (Zhao et al., 2021) incorporaron capas convolucionales al Discriminador para capturar dependencias entre variables adyacentes al reorganizar el tensor tabular como una pseudo-imagen.

No obstante, todas las variantes GAN comparten dos limitaciones estructurales inherentes a la formulación minimax. La primera es la **inestabilidad del entrenamiento**: el juego adversarial puede colapsar si el Discriminador supera al Generador demasiado rápido, saturando el gradiente del Generador (el denominado *vanishing gradient problem*). Para combatir esto, el presente trabajo empleó la variante WGAN-GP (*Wasserstein GAN with Gradient Penalty*), que reemplaza la divergencia de Jensen-Shannon original por la Distancia de Wasserstein, proporcionando un gradiente de entrenamiento más suave y estable. La segunda limitación es el fenómeno del **colapso de modo** (*mode collapse*): el Generador descubre un subespacio reducido de muestras que engañan consistentemente al Discriminador y colapsa en la repetición iterativa de esas mismas muestras, abandonando la representación de la diversidad estadística del dataset, incluyendo las clases minoritarias críticas.

2.3. Autoencoders Variacionales (VAEs)

Cofundados por Kingma y Welling (2014), los Autoencoders Variacionales (VAEs) ofrecen una perspectiva probabilística divergente, priorizando la estabilidad del entrenamiento mediante el modelado bayesiano. A diferencia del enfrentamiento minimax, un VAE consta de una red Codificadora (*Encoder*) que comprime un registro multidimensional x hacia una distribución estocástica en un espacio latente de baja dimensión $q_\phi(z|x)$. Posteriormente, una red Decodificadora (*Decoder*) extrae un punto de esa distribución y procede a reconstruir el dato original $p_\theta(x|z)$.

El objetivo del entrenamiento en un VAE no es engañar a un discriminador, sino maximizar el Límite Inferior de Evidencia (*Evidence Lower Bound* o EL-

BO). La función de pérdida se divide en dos componentes en perpetuo conflicto:

$$\mathcal{L}_{VAE} = -\mathbf{E}_{q_\phi(z|x)}[\log p_\theta(x|z)] + D_{KL}(q_\phi(z|x)||p(z))$$

El primer término actúa como una pérdida de reconstrucción clásica (fomentando copias precisas del paciente real), mientras que el segundo término es la Divergencia de Kullback-Leibler (D_{KL}), que actúa como un regularizador matemático forzando a las distribuciones latentes de los pacientes a asemejarse a una distribución normal estándar.

Esta tensión teórica (forzar a los datos reales a encajar en una única distribución continua regularizada) es, simultáneamente, la principal fortaleza y la mayor limitación de los VAEs en el dominio tabular. Mientras que en imágenes (rostros, objetos) la transición entre píxeles es continua, en los datos tabulares clínicos existe un desbalanceo agudo y una frontera discreta severa entre los pacientes sanos (clase mayoritaria) y los enfermos críticos (clase minoritaria). Al comprimir ambas realidades en un espacio latente unificado fuertemente regularizado, las redes VAE tienden a desdibujar o suavizar las fronteras de decisión de las minorías, degradando su rendimiento predictivo en métricas como el F1-Score.




Figura 2: Estructura general y regularización del espacio latente en un Auto-encoder Variacional (VAE) (Shende, 2023).

3. Modelos Probabilísticos de Difusión (Denoising Diffusion)

El panorama del aprendizaje profundo generativo experimentó un cambio de paradigma conceptual en el año 2020 con la publicación seminal de Ho et al. (2020), la cual introdujo de manera práctica y escalable los Modelos Probabilísticos de Difusión de Eliminación de Ruido (Denoising Diffusion Probabilistic Models o DDPM). Estos modelos abandonan completamente la tensión adversarial de las GANs y la compresión restrictiva de los VAEs. Su formulación se inspira directamente en la termodinámica fuera del equilibrio de la física teórica.

3.1. Fundamentos Matemáticos: Cadenas de Markov y Proceso Forward

La fundamentación matemática de los modelos de difusión reside en dividir el complejo problema de generar datos a partir de ruido aleatorio en múltiples pasos discretos de magnitud reducida de corrección. El algoritmo define un Proceso Forward (q) o proceso de destrucción paramétrico de Markov. Dada una muestra real de la distribución original $x_0 \sim p_{data}(x)$, se le inyecta una varianza controlada y programada de ruido gaussiano en cada paso t , obteniendo secuencias latentes $x_1, x_2, \dots, x_T$:

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t\mathbf{I})$$

Donde β_t es la varianza programada del ruido (el *schedule*). Una propiedad fundamental de esta cadena de Markov es que permite computar x_t directamente desde x_0 en un único paso analítico, sin necesidad de simular los t pasos intermedios. Definiendo $\alpha_t = 1 - \beta_t$ y $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$, se obtiene:

$$q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)\mathbf{I})$$

Esta simplificación, conocida como la *reparametrización de Ho et al.*, permite muestrear x_t en tiempo $O(1)$ como $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\varepsilon$, donde $\varepsilon \sim \mathcal{N}(0, \mathbf{I})$.

Si el número de pasos totales T (típicamente 1000 pasos) es lo suficientemente grande, la distribución del tensor final x_T se vuelve indistinguible de un ruido puramente aleatorio e isotrópico, condición matemáticamente necesaria para garantizar la generación desde ruido puro.

3.2. El Proceso Inverso y el Aprendizaje de Denoising

El corazón de la Inteligencia Artificial radica en aprender a ejecutar el Proceso Inverso (p_θ). Si se es capaz de enseñar a una red neuronal profunda a descontaminar estadísticamente el tensor en el paso x_t para predecir cómo era en el paso ligeramente anterior x_{t-1} , entonces la red puede tomar un ruido blanco completamente aleatorio (x_T) y reconstruir iterativamente una muestra realista (x_0):

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

La red neuronal, referida como el *Denoiser*, se entrena para estimar el ruido $\varepsilon_\theta(x_t, t)$ inyectado en el proceso forward, mediante el Error Cuadrático Medio:

$$\mathcal{L}_{simple} = \mathbf{E}_{t, x_0, \varepsilon} [||\varepsilon - \varepsilon_\theta(x_t, t)||^2]$$

Una vez entrenada la red, la media del paso inverso puede recuperarse analíticamente desde la predicción del ruido:

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \varepsilon_\theta(x_t, t) \right)$$

Como demostró Nichol y Dhariwal (2021), el rendimiento óptimo se alcanza al optimizar el planificador del ruido (*schedule* coseno), y parametrizar la red de manera que reciba el paso temporal t como una integración de codificación posicional (Timestep Embedding), permitiendo que la red sepa exactamente en qué estadio de degradación se encuentra la muestra.

El Planificador de Ruido (*Noise Schedule*). La elección del planificador β_t condiciona de forma decisiva la dinámica de aprendizaje del modelo. El planificador **lineal**, introducido por Ho et al. (2020), incrementa β_t de forma uniforme desde un valor mínimo β_1 hasta un máximo β_T , asegurando una destrucción progresiva y predecible de la información. El planificador de **coseno**, propues-

to posteriormente por Nichol y Dhariwal (2021), parametriza $\bar{\alpha}_t$ siguiendo una curva coseno que ralentiza la destrucción en los pasos iniciales, manteniendo más información durante el inicio del proceso y favoreciendo la reconstrucción de detalles finos en distribuciones de alta frecuencia, como las presentes en imágenes fotorrealistas. La elección entre ambas estrategias para el dominio tabular, y su interacción con la representación vectorial OHE de las variables categóricas, constituye uno de los ejes del estudio de ablación presentado en el Capítulo 5.




Figura 3: Procesos directo (Forward) de adición de ruido y reverso (Backward/Denoising) en modelos de difusión probabilísticos (ResearchGate, 2024).

3.3. Adaptación al Dominio Tabular: El Framework TabDDPM

Históricamente, los DDPM se popularizaron de forma abrumadora en el procesamiento de imágenes, al ser respaldados internamente por arquitecturas U-Net. Sin embargo, en un desarrollo metodológico reciente, Kotelnikov et al. (2023) publicaron TabDDPM, el primer acercamiento serio para adaptar el modelado probabilístico de la difusión a las complejas estructuras tabulares.

Dado que la difusión es un proceso estocástico que opera asumiendo espacios euclidianos y ruido gaussiano continuo, el desafío radica en el tratamiento de variables numéricas continuas/discretas y categóricas (códigos diagnósticos, razas, géneros). TabDDPM soluciona esto mediante un preprocesamiento continuo masivo: los valores numéricos son estandarizados mediante varianzas

unitarias, y las variables categóricas son transmutadas a vectores difusos mediante el uso de la codificación densa iterativa (*One-Hot Encoding*). Esta vasta matriz de variables mixtas es procesada por una red *Multi-Layer Perceptron* (MLP) con alta capacidad con conexiones residuales similares a las arquitecturas *Attention* de Vaswani et al. (2017), logrando preservar las interdependencias evitando la degradación que experimentan las redes convolucionales al carecer el texto tabular de vecindad espacial.

Una ventaja arquitectónica fundamental de TabDDPM frente a las GANs es que su proceso de entrenamiento es intrínsecamente estable: al no existir competición adversarial, el gradiente de error es un simple MSE sobre el ruido, eliminando los problemas de colapso de modo y desvanecimiento del gradiente que afectan sistemáticamente a las variantes GAN en datasets con distribuciones multimodales y clases desbalanceadas.

4. El Ecosistema de Evaluación de Datos Tabulares Sintéticos

Al carecer del componente perceptual del cual gozan las imágenes sintéticas (donde un humano puede evaluar si un rostro o paisaje es “realista” mediante inspección visual), la auditoría algorítmica de los gemelos tabulares requiere una metodología de validación estrictamente cuantitativa. Esta metodología se articula en torno a la plataforma **SDV** (*Synthetic Data Vault*) (DataCebo, Inc., 2023), un ecosistema de código abierto que proporciona tanto los motores generativos (CTGAN, TVAE) como los módulos de evaluación de calidad (*sdmetrics*) utilizados en el presente proyecto para computar las métricas de correlación y diversidad. El ecosistema de evaluación se divide en tres ejes cardinales.

4.1. Fidelidad Estadística: La Distancia de Wasserstein

Para evaluar si el modelo ha aprendido con precisión las distribuciones del mundo real, se requiere medir la divergencia entre la distribución de densidad

de los datos reales $p(x)$ y la distribución de los datos sintéticos $q(x)$. La métrica estándar de facto para variables continuas en el Deep Learning moderno es la Distancia de Wasserstein de Primer Orden (W_1), originada en los problemas matemáticos del transporte óptimo (Earth Mover's Distance) (Villani, 2008).

Conceptualmente, la distancia de Wasserstein calcula la distancia de transporte óptimo mínima indispensable para reformar una distribución de probabilidad y transmutarla para que iguale a la otra. Cuanto menor sea el coste (acercándose asintóticamente a 0.0), más indistinguibles estadísticamente son la muestra generada y la realidad subyacente. Adicionalmente, el análisis de fidelidad debe ser robustecido a nivel multivariante, calculando la Diferencia de la Matriz de Correlación MAE (*Mean Absolute Error*). Esta métrica resta iterativamente la matriz de correlación de Pearson o Cramér del dataset original a la matriz generada; una pérdida del orden del 1 % al 3 % es indicativo de un modelo eficaz capaz de preservar las reglas de negocio lógicas inherentes.

4.2. Utilidad Predictiva: El Paradigma TSTR frente a TRTR

El grado de madurez absoluto de un framework generativo no reside en su capacidad estadística descriptiva, sino en su utilidad algorítmica operativa. Para este fin, la validación se somete al riguroso protocolo formal denominado **TSTR** (*Train on Synthetic, Test on Real*). En este paradigma, es fundamental distinguirlo de sus variantes complementarias dentro de los protocolos de evaluación estándar de la literatura de síntesis de datos:

- **TRTR** (*Train on Real, Test on Real*): El clasificador externo se entrena y evalúa sobre datos reales. Constituye el *baseline* de referencia o “límite superior de rendimiento” alcanzable, ya que maximiza la disponibilidad de señal de entrenamiento.
- **TSTR** (*Train on Synthetic, Test on Real*): El clasificador se entrena exclusivamente con datos sintéticos y se evalúa sobre datos reales no observados. Es el protocolo estándar para certificar que el gemelo sintéti-

co preserva suficiente señal predictiva como para reemplazar al dataset real en un pipeline de ML.

- **TSTS** (*Train on Synthetic, Test on Synthetic*): Ambas particiones son sintéticas. Esta variante no mide la utilidad en el mundo real; solo mide la consistencia interna del modelo generativo.

En el protocolo TSTR, la IA generativa despliega el volumen total de gemelos virtuales sin incluir un solo paciente biológico genuino. Este cuerpo sintético se emplea de forma hermética para entrenar un clasificador predictivo externo. Dada su contrastada resistencia al sobreajuste, la herramienta predictiva predilecta suele ser *XGBoost* (Chen & Guestrin, 2016). Posteriormente, este modelo se despliega para ejecutar su función predictiva sobre el grupo de datos reales de prueba (*Holdout Test Set*) extraído al inicio del experimento y que jamás fue observado. El desempeño del clasificador entrenado por la inteligencia sintética se compara directamente contra el *baseline* (un modelo idéntico instruido con pacientes biológicos genuinos). Si el margen de pérdida predictiva, tasado en métricas de clasificación pesada como la curva ROC-AUC o el F1-Score armónico, es inferior al 5.0 %, el ecosistema generativo se certifica como un repuesto integralmente compatible (*Drop-In Replacement*) con garantías operativas óptimas en ambientes clínicos industriales.

4.3. Privacidad Empírica: DCR y MIA como Vectores de Auditoría

El tercer eje de la evaluación, y el más crítico desde la perspectiva regulatoria, es la auditoría de la privacidad empírica. Como se detalló en la sección 1.4, los dos vectores de ataque fundamentales que deben neutralizarse son la Memorización (DCR) y la Inferencia de Membresía (MIA). Un modelo generativo que supere favorablemente ambas auditorías mostrando un DCR mínimo estrictamente mayor que cero y un AUC del atacante MIA estadísticamente indistinguible de 0.50 habrá demostrado que sus datos sintéticos cumplen los tres criterios del Dictamen del Artículo 29 (individualización, vinculación e inferencia), obteniendo el aval legal para su clasificación como datos anónimos

fuera del alcance del GDPR.

Capítulo 4: Marco Metodológico

Este capítulo detalla la metodología adoptada para el desarrollo y validación del proyecto. Se documenta el entorno de desarrollo y la infraestructura de computación, el origen y procesamiento de la muestra clínica original, la arquitectura e implementación de las redes neuronales generativas, y los protocolos diseñados para evaluar la utilidad estadística y la privacidad de los datos sintéticos.

1. Infraestructura y Entorno de Ejecución

La síntesis de datos tabulares a gran escala mediante Modelos Probabilísticos de Difusión exige una capacidad de cómputo sustancial. El paradigma de adición iterativa de ruido (Proceso Forward) y la posterior predicción de la corrección estocástica (Proceso Inverso) a lo largo de cientos de pasos temporales genera una limitación computacional crítica para las Unidades Centrales de Procesamiento (CPU) tradicionales.

Para solventar esta barrera, la experimentación técnica de este proyecto fue delegada en su totalidad a un entorno de computación acelerada por *hardware*. El clúster físico utilizado está equipado con una Unidad de Procesamiento Gráfico (GPU) **AMD Radeon RX 9070**. Esta arquitectura gráfica proporcionó el paralelismo masivo necesario para computar la multiplicación de tensores requerida durante el proceso de retropropagación (*backpropagation*).

A nivel de ecosistema de *software*, se priorizó la reproducibilidad científica y el aislamiento operativo. Todo el entorno de desarrollo fue virtualizado mediante el uso de contenedores **Docker**, garantizando que las dependencias de librerías y las configuraciones de los controladores de GPU permanecieran inmutables independientemente de la máquina huésped subyacente. El lenguaje

principal de programación elegido fue Python 3.10. El *backend* de Deep Learning que sustentó los grafos computacionales de las tres arquitecturas generativas fue **PyTorch** (Paszke et al., 2019). Para la orquestación de la evaluación, el entrenamiento del oráculo predictivo y la codificación de métricas secundarias, se recurrió a las potentes bibliotecas de *Synthetic Data Vault* (SDV) (DataCebo, Inc., 2023), *Scikit-Learn* y **XGBoost** (Chen & Guestrin, 2016).

2. Origen de Datos y Análisis Exploratorio

2.1. El Conjunto de Datos Clínico

El entorno de pruebas de un modelo generativo es crítico para evaluar su eficacia en el mundo real. En lugar de optar por un conjunto de datos sintético o artificialmente perfeccionado, la investigación basó su núcleo analítico en el dataset *Diabetes 130-US Hospitals* (Strack et al., 2014). Este corpus constituye un extracto masivo y longitudinal de registros de pacientes ingresados en más de un centenar de hospitales estadounidenses entre los años 1999 y 2008.

El volumen bruto original comprende un total de **101.766 historias clínicas** de pacientes diagnosticados con diabetes en el repositorio de la UCI. Cada registro original está descrito por 50 variables (13 numéricas y 37 categóricas), que incluyen métricas demográficas (edad, raza, género), características administrativas (tiempo de estancia hospitalaria, número de procedimientos médicos, cantidad de diagnósticos) y posología altamente detallada indicando la administración o modificación de medicamentos específicos para la diabetes, como la metformina o la insulina.

2.2. El Desafío del Desbalanceo y el Objetivo Predictivo

El núcleo del desafío algorítmico gravita en torno a la variable objetivo (el *target*): la predicción del reingreso hospitalario temprano, denotado por la columna *readmitted*. En el contexto sanitario, anticipar si un paciente diabético va a sufrir una recaída y deberá ser reingresado en los próximos 30 días es una métrica vital para mitigar la saturación de los servicios de urgencias y optimizar la gestión global de los recursos hospitalarios de hospitalización general.

En el conjunto original, esta variable exhibía tres categorías (“NO”, “>30”, “<30”). Para enfocar el problema hacia un objetivo de optimización operativa, la variable fue binarizada en dos clases fundamentales: *Reingreso Crítico* (pacientes readmitidos en menos de 30 días) frente a *No Reingreso/Tardío*. Esta transformación expuso el mayor obstáculo técnico del proyecto: un severo desbalanceo de clases intrínseco. Aproximadamente el **88.6 %** de los pacientes pertenecían a la clase mayoritaria (pacientes estables), mientras que tan solo un **11.4 %** conformaban la clase minoritaria crítica.

Cualquier modelo de IA tradicional tendería a colapsar y predecir simplemente que ningún paciente reingresa, obteniendo de este modo una precisión base artificialmente alta del 88.6 %. Por lo tanto, obligar a una red neuronal generativa a capturar el minúsculo patrón subyacente del 11.4 % sin destruirlo bajo el peso de la clase dominante constituye un desafío de modelado estadístico representativo de este estudio.




Figura 4: Distribución de la variable objetivo binarizada (Clase Mayoritaria vs. Clase Minoritaria Crítica) obtenida del conjunto de datos clínico original.

2.3. Ingeniería de Características y Limpieza

Previo a la ingesta del tensor por las redes neuronales, se orquestó una rigurosa tubería (*pipeline*) de Ingeniería de Características y Limpieza de datos. En primer lugar, se aplicó un criterio de exclusión clínica eliminando **2.423 registros** correspondientes a pacientes fallecidos o dados de alta hacia cuidados paliativos (*hospice*), ya que su inclusión introduciría un sesgo artificial en la predicción de reingresos a corto plazo. Adicionalmente, se purgaron **3 registros** debido a inconsistencias de codificación en la variable de género. Esta depuración de filas redujo la muestra original de 101.766 a un conjunto maestro consolidado de exactamente **99.340 registros**, garantizando una trazabilidad exacta del flujo de datos. En segundo lugar, se suprimieron columnas con un grado de completitud nulo extremo (como la variable `weight` con un 96.86 % de valores faltantes o `payer_code`) e identificadores técnicos sin valor predictivo (`encounter_id` y `patient_nbr`), reduciendo el espacio de variables de 50 a un total de **39 columnas** clínicas útiles. Las variables categóricas con alta cardinalidad (como los códigos médicos ICD-9 originales que presentan más de 700 valores distintos) fueron consolidadas y colapsadas en 9 categorías clínicas estándar para optimizar el aprendizaje del motor generativo. Tras este proceso de sanitización, el conjunto consolidado garantizó la total ausencia de valores nulos (NaNs), estabilizando el cálculo del gradiente de error.

2.4. Descripción del Espacio de Variables Consolidado

Tras la fase de limpieza e ingeniería de características, el conjunto de datos consolidado de 99.340 registros queda descrito por las 39 variables detalladas en la Tabla 1. Se distinguen dos grandes grupos: las **9 variables numéricas** (continuas o discretas), cuyos estadísticos descriptivos reflejan la complejidad de la casuística hospitalaria, y las **30 variables categóricas** (nominales u ordinales), que abarcan desde la demografía del paciente hasta la posología de 23 medicamentos antidiabéticos específicos.

Tabla 1: Espacio de Variables del Conjunto Clínico Consolidado (99.340 registros)

Variable	Tipo	Descripción clínica
<i>Variables Numéricas</i>		
time_in_hospital	Discreta	Días de estancia hospitalaria (rango: 1–14)
num_lab_procedure	Discreta	Número de análisis clínicos realizados (1–132)
num_procedures	Discreta	Número de procedimientos médicos (0–6)
num_medications	Discreta	Medicamentos distintos administrados (1–81)
number_outpatient	Discreta	Visitas ambulatorias en el año previo (0–42)
number_emergency	Discreta	Urgencias en el año previo (0–76)
number_inpatient	Discreta	Ingresos hospitalarios en el año previo (0–21)
number_diagnoses	Discreta	Diagnósticos registrados en el episodio (1–16)
prior_visits	Discreta	Visitas previas totales (variable construida: outpatient + emergency + inpatient)
<i>Variables Categóricas (selección de las más representativas)</i>		
race	Nominal	Etnia del paciente (5 categorías)
gender	Binaria	Género del paciente
age	Ordinal	Grupo de edad en intervalos de 10 años ([0-10] a [90-100])
admission_type_i	Nominal	Tipo de admisión (urgencia, electiva, recién nacido, etc.)
diag_1 / diag_2 / diag_3	Nominal	Diagnóstico primario y secundarios (9 macro-categorías ICD-9)
insulin	Ordinal	Régimen de insulina (No, Steady, Up, Down)
metformin	Ordinal	Régimen de metformina (No, Steady, Up, Down)
diabetesMed	Binaria	Indicador de prescripción de medicación antidiabética
change	Binaria	Cambio en la medicación durante el ingreso
readmitted	Binaria	Variable objetivo: reingreso <30 días (1) vs. otro (0)
<i>Nota: Se incluyen 19 columnas adicionales de medicamentos antidiabéticos (repaglinide, glipizide, etc.) no deta</i>		

2.5. Análisis Exploratorio Cuantitativo

Previo al entrenamiento de los modelos generativos, se realizó un Análisis Exploratorio de Datos (EDA) exhaustivo sobre el conjunto consolidado de 99.340 registros, documentado en el cuaderno `01_eda_detallado.ipynb`. La Tabla 2 sintetiza los estadísticos descriptivos de las 9 variables numéricas tras la limpieza. Destacan varios patrones clínicamente relevantes: la elevada varianza en `num_lab_procedures` (desv. típica de 19.7), indicativa de la heterogeneidad de los protocolos diagnósticos entre hospitales; y la distribución fuertemente asimétrica y concentrada en cero de las variables de visitas previas (`number_outpatient`, `number_emergency`, `number_inpatient`), características de distribuciones de eventos de cola larga (*heavy-tailed*) que representan un reto adicional para los modelos generativos, ya que deben capturar tanto el pico en cero como los valores extremos infrecuentes.

Cabe señalar un aspecto metodológico clave respecto a la variable construida `prior_visits`, la cual se define por la dependencia lineal exacta: `prior_visits = number_outpatient + number_emergency + number_inpatient`. Al entrenar los modelos generativos sin restricciones externas, existe el riesgo intrínseco de que las muestras sintéticas violen esta relación determinista debido a la naturaleza estocástica de la generación. En este trabajo, se optó por incluir las cuatro variables en el entrenamiento con el fin de evaluar la capacidad de los modelos para capturar implícitamente esta correlación colineal en el espacio latente. Sin embargo, en un entorno de producción o despliegue real, se puede garantizar la integridad absoluta de esta regla de negocio aplicando una de dos estrategias: (i) omitir la generación de `prior_visits` y calcularla de forma determinista post-generación como la suma de las otras tres variables, o (ii) aplicar un operador de proyección post-procesado que recalculé el total sintético para asegurar consistencia matemática.

Respecto a las variables categóricas, el análisis de frecuencias reveló que la población mayoritaria corresponde a pacientes de raza caucásica (75.4 %), de género femenino (53.1 %) y en el grupo de edad de [70-80] años (21.6 %). La insulina es el medicamento antidiabético más prevalente, presente de forma activa en el 53.4 % de los registros, seguida de la metformina (con un régimen activo en el 30.5 %). Estos desequilibrios en la distribución de las variables

Tabla 2: Estadísticos Descriptivos de las Variables Numéricas (Conjunto Consolidado, $n = 99,340$)

Variable	Media	Desv. Típica	Mín.	Mediana	Máx.
time_in_hospital	4.40	2.99	1	4	14
num_lab_procedures	43.10	19.67	1	44	132
num_procedures	1.34	1.71	0	1	6
num_medications	16.00	8.07	1	15	81
number_outpatient	0.37	1.27	0	0	42
number_emergency	0.20	0.93	0	0	76
number_inpatient	0.57	1.24	0	0	21
number_diagnoses	7.40	1.94	1	8	16
prior_visits	1.13	2.17	0	0	100

categorías constituyen un vector de complejidad adicional para los modelos generativos: el modelo debe aprender no solo las distribuciones marginales de cada variable, sino también las correlaciones cruzadas entre ellas (por ejemplo, la correlación entre el grupo de edad avanzada, la prescripción de insulina y la mayor frecuencia de reingresos).

3. Desarrollo e Implementación de Modelos Generativos

Para validar exhaustivamente la supremacía de la tecnología de difusión, la metodología no consistió en ejecutar el modelo en el vacío, sino en implementarlo y enfrentarlo algorítmicamente contra los dos grandes paradigmas reinantes de la IA Generativa adaptados al dominio tabular.

3.1. Línea Base Adversarial: CTGAN

El primer pilar de experimentación consistió en la codificación de una Red Generativa Antagónica Condicional Tabular (**CTGAN**). Como línea base, el Generador y el Discriminador fueron parametrizados bajo una arquitectura Multi-Layer Perceptron (MLP) utilizando el marco estandarizado de la literatura.

tura. El modelo fue dotado de un Preprocesamiento de Modo-Específico (VGM, por sus siglas en inglés) para transformar el espacio complejo de las variables numéricas multimodales. Las redes fueron instruidas a lo largo de 300 épocas (*epochs*) de entrenamiento utilizando el optimizador adaptativo Adam y una función de pérdida optimizada mediante el castigo del gradiente de Wasserstein (WGAN-GP), estabilizando la convergencia dinámica del juego minimax.

3.2. Línea Base Bayesiana: TVAE

El segundo pilar consistió en el despliegue de un Autoencoder Variacional Tabular (**TVAE**). Su topología se basó en una simetría en embudo: un codificador comprimiendo progresivamente los 41 tensores de entrada hacia un cuello de botella denso (el espacio latente estocástico), y un decodificador forzado a reconstruir la dimensionalidad original minimizando una pérdida combinada de reconstrucción categórica (Entropía Cruzada Múltiple) y reconstrucción continua (Error Cuadrático Medio), regularizado por la divergencia de Kullback-Leibler. Al igual que el modelo adversarial, se sometió al conjunto de datos a 300 épocas de instrucción para asegurar una comparación empírica en condiciones equivalentes de entrenamiento.

3.3. Arquitectura Propuesta: TabDDPM

La fase de implementación se centró en la arquitectura probabilística **TabDDPM**. El modelo fue codificado desde sus cimientos para operar bajo un régimen de difusión escalonada. El hiperparámetro maestro del ecosistema fue fijado en $T = 1000$ pasos temporales para la configuración final de referencia (tal como se documenta en el estudio de ablación del Capítulo 5). El planificador de ruido (*noise schedule*) fue parametrizado siguiendo un decaimiento lineal suave, con $\beta_1 = 10^{-4}$ y $\beta_T = 0,02$.

Etapas de Preprocesamiento. Para operar sobre datos mixtos, el framework TabDDPM implementa una etapa de preprocesamiento acoplada mediante la

clase `TabularPreprocessor`. Las **9 variables numéricas** continuas y discretas son normalizadas mediante un escalador estándar de media cero y varianza unitaria (*StandardScaler*). Paralelamente, las **30 variables categóricas** incluyendo los diagnósticos clínicos ICD-9 previamente consolidados en 9 macro-categorías nominales son sometidas a codificación *One-Hot* (OHE). La Tabla 3 detalla la dimensionalidad resultante del vector latente tras la aplicación de este proceso de codificación mixta.

Tabla 3: Composición del Vector de Entrada al Modelo TabDDPM (Dimensión Total: 139)

Grupo de variables	Variables originales	Dimensiones en el tensor
Numéricas (<i>StandardScaler</i>)	9	9
Categóricas (One-Hot Encoding)	30	130
Total	39	139

El vector resultante de 139 dimensiones es procesado por la capa de proyección de entrada (`input_proj`) de la red `DenoisingMLP`. En la fase de inferencia (muestreo), el tensor de salida de 139 dimensiones es decodificado mediante la transformada inversa del preprocesador, aplicando la transformación inversa del *StandardScaler* para las variables numéricas y un operador de máxima probabilidad (*argmax*) en cada bloque OHE para reconstruir el valor categórico discreto original.

Arquitectura de la Red de Denoising (`DenoisingMLP`). La red neuronal encargada de aprender el proceso inverso de difusión fue diseñada como un MLP con conexiones residuales (*ResBlocks*) e integración del embedding del instante temporal. La arquitectura se descompone en los siguientes módulos:

- 1. Sinusoidal Timestep Embedding:** Inspirado en el mecanismo de codificación posicional de los Transformers (Vaswani et al., 2017), este módulo transforma el índice temporal escalar $t \in \{0, \dots, T - 1\}$ en un vector de alta dimensión (128 dimensiones) mediante la superposición de funciones sinusoidales de frecuencias logarítmicamente espaciadas. Esto permite a la red identificar geoméricamente el nivel de degradación

presente en su entrada x_t sin necesidad de embeddings aprendidos.

- 2. Capa de Proyección de Entrada:** Una capa lineal proyecta el vector de entrada de 139 dimensiones al espacio oculto de 512 características.
- 3. Bloques Residuales (ResBlocks):** Tres bloques residuales secuenciales, cada uno compuesto por una capa de normalización de capas (*LayerNorm*), dos capas lineales de 512 neuronas con activación SiLU (*Sigmoid Linear Unit*), y una capa de proyección del embedding temporal. La contribución del embedding de instante se suma aditivamente a la activación de cada bloque, implementando el condicionamiento temporal de la red.
- 4. Capa de Salida:** Una capa lineal proyecta de vuelta las 512 dimensiones ocultas a las 139 dimensiones del espacio de entrada, produciendo la predicción del ruido $\hat{\epsilon}_\theta(x_t, t)$.

La red `DenoisingMLP` resultante acumula un total de **1.097.483 parámetros entrenables**, optimizados mediante el algoritmo *AdamW* con una tasa de aprendizaje de 10^{-3} y un decaimiento de pesos de 10^{-4} . Un planificador de tasa de aprendizaje coseno (*CosineAnnealingLR*) fue aplicado sobre el optimizador para reducir progresivamente la tasa de aprendizaje durante las fases finales del entrenamiento, favoreciendo la convergencia fina.

4. Diseño de Protocolos de Evaluación y Auditoría

Un gemelo sintético no adquiere valor por su existencia, sino por las garantías matemáticas que lo sustentan. Por consiguiente, el marco metodológico incorporó tres auditorías programáticas para sancionar empíricamente el volumen de datos generado.

4.1. Protocolo TSTR (Train on Synthetic, Test on Real)

El paradigma TSTR materializó el eje de evaluación de Utilidad Predictiva. Originalmente, el dataset consolidado de 99.340 filas se dividió en dos particiones irreconciliables: un Conjunto de Entrenamiento (*Train*, 70 %) y un Conjunto de Prueba del mundo real (*Holdout Test*, 30 %).

Los tres modelos generativos estudiados (CTGAN, TVAE y TabDDPM) fueron nutridos única y exclusivamente con el 70 % del Conjunto de Entrenamiento, operando en total ceguera respecto al Conjunto de Prueba. Tras completarse sus épocas, cada generador sintetizó un volumen idéntico de datos virtuales. Estos datos ficticios fueron empleados para instruir tres instancias vírgenes y autónomas de un modelo clasificador **XGBoost** (uno por cada tecnología sintética). Finalmente, cada XGBoost se desplegó sobre el Conjunto de Prueba del mundo real (Holdout 30 %), midiendo su capacidad para predecir correctamente la clase minoritaria crítica. Las métricas cosechadas (F1-Score y AUC-ROC) fueron entonces comparadas contra un “Oráculo Baseline” que fue entrenado con datos reales (baseline TRTR). El modelo generativo que presente la menor brecha (*gap*) respecto a este baseline presentará el mejor desempeño en utilidad predictiva.

4.2. Medición de Fidelidad: Distancia Multivariante

Más allá del rendimiento algorítmico, el marco metodológico garantizó que los datos sintetizados respetasen las reglas de negocio biológicas y lógicas. Para cada modelo, se orquestó un bucle computacional que contrastó la Distancia de Wasserstein unidimensional columna por columna. Adicionalmente, para blindar las interdependencias cruzadas complejas (por ejemplo, asegurar que la edad de un paciente concuerde estadísticamente con la prescripción de sus medicamentos para la diabetes), se generaron las matrices de correlación de Pearson-Cramér, calculándose el *Mean Absolute Error* (MAE) en las desviaciones matriciales entre los pacientes biológicos y los gemelos sintéticos.

4.3. Auditorías de Privacidad (GDPR)

La fase final de la metodología consistió en la evaluación de la privacidad empírica de los modelos generativos mediante dos auditorías complementarias de seguridad. En primer lugar, para cuantificar el riesgo de copia o memorización de datos reales, se implementó un algoritmo de búsqueda de vecino más cercano (*K-Nearest Neighbors*) en el espacio euclidiano para calcular la métrica DCR (*Distance to Closest Record*) entre cada registro sintético y el conjunto real. En segundo lugar, se evaluó la vulnerabilidad frente a ataques de inferencia de membresía (MIA), entrenando un clasificador para intentar predecir si un paciente clínico pertenecía o no al conjunto de entrenamiento original a partir de su distancia al dato sintético más cercano.

Capítulo 5: Análisis y Resultados

Tras la culminación de las fases de diseño metodológico y entrenamiento de los algoritmos generativos detalladas en el capítulo anterior, esta sección expone la síntesis de los resultados empíricos obtenidos. El núcleo de este capítulo radica en contrastar el rendimiento del Modelo Probabilístico de Difusión propuesto (*TabDDPM*) frente a los paradigmas adversariales (CTGAN) y bayesianos (TVAE) considerados como líneas base del estado del arte.

Los resultados se estructuran en cuatro dimensiones analíticas fundamentales: en primer lugar, se analiza la convergencia del entrenamiento del modelo de difusión; en segundo lugar, se evalúa la fidelidad estadística y estructural de los gemelos digitales; en tercer lugar, se cuantifica la utilidad predictiva y el impacto de negocio mediante el despliegue de un oráculo algorítmico externo; y finalmente, se presentan los dictámenes de las simulaciones de ciberataques requeridas para garantizar el cumplimiento normativo exigido por el Reglamento General de Protección de Datos (GDPR). Adicionalmente, se integra un estudio de ablación intra-arquitectónico diseñado para destilar la configuración óptima del ecosistema de difusión.

1. Convergencia del Entrenamiento: Análisis de la Curva de Pérdida

El entrenamiento del modelo *TabDDPM* se llevó a cabo durante un total de **1.000 épocas**, utilizando el optimizador AdamW con un planificador de tasa de aprendizaje coseno (*CosineAnnealingLR*). La evolución de la función de pérdida MSE a lo largo del entrenamiento refleja una dinámica de convergencia característica de los modelos de difusión y proporciona información relevante sobre la estabilidad del proceso de aprendizaje.

Durante las primeras épocas de entrenamiento, la pérdida descendió de forma abrupta: desde un valor inicial de **0.619** en la primera época hasta **0.170** en la tercera época, evidenciando que la red neuronal aprendió rápidamente las macropatrones de ruido más prominentes del espacio latente de 139 dimensiones. Esta fase de descenso brusco es característica del aprendizaje de las componentes de baja frecuencia de la distribución de datos, es decir, las tendencias globales de las variables más representadas (como la distribución dominante de la clase mayoritaria de pacientes no reingresados). A partir de la época 100, el aprendizaje transitó a una fase de refinamiento progresivo de los patrones de alta frecuencia las correlaciones entre variables minoritarias y los matices de las distribuciones de cola donde la pérdida descendió gradualmente hasta estabilizarse en torno a **0.041** al final de las 1.000 épocas de entrenamiento. La ausencia de oscilaciones erráticas o incrementos súbitos en la pérdida confirma la estabilidad intrínseca del régimen de difusión frente a los entornos adversariales de las GANs, donde el equilibrio minimax puede romperse de forma impredecible.

Esta convergencia estable contrasta marcadamente con el comportamiento típico de las GANs entrenadas en el mismo dominio: la pérdida del discriminador CTGAN exhibe oscilaciones de alta amplitud durante las primeras 50 épocas, un síntoma del juego adversarial que alterna fases de dominio del Generador y del Discriminador. Del mismo modo, la pérdida ELBO del TVAE, si bien converge con mayor rapidez gracias a la naturaleza no adversarial de su entrenamiento, presenta una meseta prematura que indica que el término de regularización KL frena el aprendizaje de los modos de baja frecuencia asociados a la clase minoritaria.

2. Fidelidad Estadística y Preservación Estructural

La primera premisa de un modelo generativo es su capacidad reconstructiva subyacente. Los datos no deben meramente “parecer” reales a nivel marginal (columna por columna), sino que deben preservar el delicado tejido de interdependencias multivariantes clínicas, tales como la correlación inherente entre el diagnóstico de una neuropatía y la consecuente administración prolongada de metformina.

2.1. Distancia de Wasserstein por Variable

La Tabla 4 presenta la Distancia de Wasserstein (W_1) calculada para cada una de las 9 variables numéricas del conjunto consolidado, desagregando los resultados por los tres modelos evaluados. Estos valores permiten identificar qué variables presentan mayor dificultad de síntesis y qué arquitectura las captura con mayor fidelidad.

Tabla 4: Distancia de Wasserstein por Variable Numérica y Modelo (valores menores indican mayor fidelidad)

Variable	CTGAN	TVAE	TabDDPM
time_in_hospital	0.550	0.204	0.303
num_lab_procedures	4.353	3.057	2.307
num_procedures	0.060	0.496	0.299
num_medications	1.908	1.143	1.133
number_outpatient	0.110	0.060	0.042
number_emergency	0.068	0.133	0.049
number_inpatient	0.235	0.143	0.072
number_diagnoses	0.646	0.546	0.133
prior_visits	0.312	0.220	0.097
Media Global	0.762	0.601	0.397

El análisis por variable revela patrones clínicamente interpretables. La variable `num_lab_procedures` es, con diferencia, la más difícil de sintetizar para todos los modelos (con distancias en el rango 2–4), lo cual es consistente con su amplio rango (1 a 132) y la heterogeneidad de los protocolos diagnósticos entre los 130 hospitales del dataset. Sin embargo, **TabDDPM** logra reducir la distancia en esta variable a 2,307, frente a los 4,353 de CTGAN (−47%). Las variables de visitas previas (`number_outpatient`, `number_emergency`, `number_inpatient` y `prior_visits`), caracterizadas por distribuciones de cola larga fuertemente concentradas en cero, son sintetizadas con notable precisión por TabDDPM, con distancias inferiores a 0,10 en todos los casos. Este rendimiento es atribuible a la capacidad del proceso de difusión reversa para aprender distribuciones multimodales con componentes de masa puntual, superando la tendencia del TVAE a promediar estas distribuciones (“suavizado” producido por la regularización KL) y la propensión del CTGAN al colapso de modo en los valores extremos de la distribución de cola.

2.2. Análisis de la Estructura de Correlación Multivariante

Para cuantificar el fenómeno de preservación de las interdependencias cruzadas, se calculó la Divergencia de Matrices de Correlación MAE (*Mean Absolute Error*). Esta métrica mide la disimilitud absoluta media entre la matriz de correlación empírica calculada sobre los 99.340 pacientes biológicos reales frente a la matriz construida por los pacientes virtuales. Las Figuras 5, 6 y 7 exponen los mapas de calor (*heatmaps*) residuales. Cabe destacar que, para evitar la saturación visual derivada de graficar simultáneamente las 39 variables del conjunto consolidado, estos mapas muestran una submatriz representativa de 13 variables principales (incluyendo las 9 variables numéricas y las categóricas discretas de mayor relevancia clínica e impacto predictivo). En estos mapas, un tono azul oscuro indica la supresión artificial de una correlación existente, los tonos rojizos indican la sobreestimación de una correlación inexistente en la población real, y el blanco absoluto testifica la reproducción exacta de la correlación de las variables clínicas.




Figura 5: Mapa residual de Diferencia de Correlación para CTGAN. Obsérvense las sobreestimaciones en la correlación (tonos rojos) causadas por la inestabilidad adversarial.




Figura 6: Mapa residual de Diferencia de Correlación para TVAE. La regularización bayesiana difumina agresivamente las fronteras, destruyendo la señal minoritaria.




Figura 7: Mapa residual de Diferencia de Correlación para TabDDPM. La prevalencia de tonos claros en la matriz de diferencia certifica una reconstrucción precisa de la estructura de covarianza original.

El análisis visual y matemático de las matrices constata que el *Baseline Adversarial* (CTGAN) adolece de desviaciones estadísticas significativas, inventando cruces espurios a causa del colapso de modo (MAE de correlación: 0.0675). Por el contrario, la red de difusión *TabDDPM* logra reproducir las correlaciones con una pérdida ínfima (MAE de correlación: **0.0122**). El proceso iterativo de eliminación de ruido logra capturar las sutilezas geométricas sin perder la estructura fina de correlación como hace el modelo *TVAE* (MAE: 0.0395).

3. Utilidad Predictiva: Evaluación TSTR

Superada la validación estructural, la fase final de la validación se enfocó en la viabilidad operativa para el sector sanitario corporativo. Para ello, se aplicó estrictamente el protocolo TSTR (*Train on Synthetic, Test on Real*), delegando en *XGBoost* la labor de discriminar a los pacientes con alta probabilidad de reingreso hospitalario temprano (en un plazo inferior a 30 días).

La Tabla 5 expone las métricas comparativas del oráculo al ser entrenado de forma aislada con cada volumen de datos. El *Baseline Real* marca el límite superior de rendimiento para este problema médico altamente desbalanceado: entrenando el modelo *XGBoost* exclusivamente con datos biológicos reales, se alcanza un F1-Score de **0.5906** en el conjunto de prueba aislado (*Holdout Set*).

Tabla 5: Resultados del Protocolo Predictivo TSTR (XGBoost Oracle)

Origen de Entrenamiento	ROC-AUC	F1-Score	Brecha vs Real (Δ)
Baseline Biológico (TRTR)	0.6879	0.5906	—
TVAE (Autoencoder Variacional)	0.6660	0.4486	-24.04 %
CTGAN (Red Antagónica)	0.6143	0.5393	-8.68 %
TabDDPM (Modelo de Difusión)	0.6567	0.5965	+0.99 %

Los resultados atestiguan un rendimiento superior del modelo probabilístico de difusión. Mientras que el *TVAE* presenta una notable degradación en su rendimiento debido a la penalización de la Divergencia KL sobre las clases po-

co frecuentes (precipitando el rendimiento un $-24,04\%$), TabDDPM logra reconstruir las intrincadas fronteras de decisión de los pacientes de riesgo crítico, alcanzando un F1-Score de **0.5965**, que supera en un $+0,99\%$ al modelo baseline entrenado con datos reales. Este resultado, que puede parecer contraintuitivo, es estadísticamente consistente: el modelo generativo, al haber aprendido a generar muestras de la clase minoritaria con mayor diversidad que las presentes en el conjunto de entrenamiento original, actúa implícitamente como un mecanismo de aumento de datos (*data augmentation*), mejorando la capacidad de generalización del clasificador downstream. Estos números certifican que el gemelo sintético generado por difusión está capacitado para actuar como un sustituto funcional total (*Drop-In Replacement*) en sistemas de soporte a decisiones clínicas (CDSS).

4. Estudio de Ablación Intra-Arquitectónico

4.1. Ablación sobre TabDDPM: Impacto del Schedule y los Pasos de Difusión

En la frontera investigativa del aprendizaje profundo tabular, la configuración del *schedule* de ruido (la cadencia matemática con la que se contamina el dato real durante la fase Forward) y el número de pasos de Markov (T) suscitan amplios debates. Para fundamentar empíricamente las decisiones ingenieriles, se condujo un estudio de ablación sobre el motor TabDDPM con cuatro configuraciones:

Tabla 6: Estudio de Ablación sobre Parámetros de Difusión en TabDDPM

Configuración	WD Media	Corr. MAE	F1-Score	Gap
V1 — Lineal, $T = 1000$	0.493	0.0112	0.5965	+1.00 %
V2 — Coseno, $T = 1000$	169.94	0.3165	0.5349	-9.43 %
V3 — Lineal, $T = 500$	0.767	0.0113	0.5650	-4.34 %
V4 — Coseno, $T = 500$	51.36	0.3951	0.5565	-5.77 %
Configuración Final (V1)	0.493	0.0112	0.5965	+1.00 %

Los resultados del ablation study revelan un hallazgo fundamental: el planificador de coseno (*cosine schedule*), considerado el estado del arte para la generación de imágenes fotorrealistas, se muestra **claramente inferior** en el dominio tabular. Las configuraciones con *schedule* coseno (V2 y V4) presentan distancias de Wasserstein medias de 169.94 y 51.36 respectivamente, valores que son de uno a dos órdenes de magnitud superiores a sus contrapartes lineales. Este fenómeno tiene una explicación estructural: el *schedule* coseno ralentiza la destrucción de información en los primeros pasos del proceso forward, manteniendo las representaciones OHE de las variables categóricas parcialmente intactas durante un período prolongado. Sin embargo, las representaciones OHE son vectores binarios dispersos (en su mayoría ceros con un único uno), y al añadir ruido gaussiano de baja magnitud sobre ellos, se generan estados intermedios con distribuciones uniformes sobre el bloque OHE (valores cercanos a $1/k$ para una variable con k categorías). El denoiser no logra recuperar una señal de gradiente clara en estos estados intermedios, lo que genera incoherencias en el proceso de muestreo reverso y produce distribuciones categóricas espúreas. El decaimiento lineal, al destruir la información más rápidamente, evita estos estados ambiguos y permite que el *argmax* durante la generación seleccione categorías coherentes.

Respecto al número de pasos T , la reducción de 1000 a 500 pasos (V3 vs. V1) produce una leve degradación del F1-Score (de +1,00 % a -4,34 %), al precio de reducir el tiempo de inferencia a la mitad. La configuración V1 (Lineal, $T = 1000$) fue seleccionada como la parametrización de referencia por ofrecer la mejor combinación de fidelidad y utilidad predictiva.

4.2. Ablación sobre TVAE: Análisis de la Limitación Estructural

Para investigar si la severa degradación del TVAE (-24,04 % en F1 respecto al baseline real) era atribuible a una configuración sub-óptima de hiperparámetros o a una limitación estructural del paradigma VAE en datos desbalanceados, se condujo un segundo estudio de ablación variando el *loss factor* (ponderación del término de reconstrucción sobre la divergencia KL) y la dimensionalidad del espacio latente.

Tabla 7: Estudio de Ablación sobre Hiperparámetros del TVAE

Configuración	LF	Dim.	WD Media	F1	Gap
V1 — Baseline	2	128	0.727	0.4486	−24.04 %
V2 — Mayor reconstrucción	5	128	1.069	0.4234	−28.31 %
V3 — Reconstrucción dominante	10	128	1.194	0.4795	−18.81 %
V4 — Mayor capacidad latente	5	256	0.529	0.3386	−42.67 %
Mejor variante (V3)	10	128	1.194	0.4795	−18.81 %

Nota: LF = *loss_factor*; Dim. = *embedding_dim*.

Los resultados confirman la hipótesis de **limitación estructural**. Ninguna combinación de hiperparámetros logró superar la brecha del -5% respecto al baseline real. La mejor variante (V3, con *loss_factor*= 10) reduce la brecha hasta el $-18,81\%$, lo cual demuestra que el modelo sufría una *dominancia del término KL*: al ponderar excesivamente la regularización bayesiana sobre el término de reconstrucción, la distribución latente era forzada a adoptar una gaussiana isotrópica que borraba las regiones de baja densidad asociadas a la clase minoritaria. Sin embargo, al elevar agresivamente el *loss factor* (V3 y V4), aumenta la distancia de Wasserstein media (de 0.727 a 1.194), revelando el compromiso (*trade-off*) entre la fidelidad estadística de las distribuciones marginales y la capacidad predictiva downstream en este paradigma.

La amplitud del espacio latente (V4, *embed_dim*= 256) no solo no mejora los resultados sino que los empeora hasta el $-42,67\%$, lo que sugiere que un espacio latente de mayor dimensión exacerba la maldición de la dimensionalidad (*curse of dimensionality*): con 256 dimensiones libres, el decodificador dispone de suficiente capacidad para colapsar todos los registros de la clase minoritaria en regiones periféricas de baja densidad del espacio latente, que quedan regularizadas hacia el origen por el término KL y prácticamente desaparecen durante la decodificación. Esta limitación es consistente con las observaciones documentadas en la literatura por El Emam et al. (2020) y Stadler et al. (2022).

5. Auditoría Legal y Privacidad Empírica (GDPR)

La fase final de la validación se centra en la viabilidad regulatoria. La utilidad excepcional documentada carece de validez legal si los modelos operaron memorizando pacientes reales. Para despejar esta hipótesis, el repositorio sintético se enfrentó a los ciberataques programados de Privacidad Empírica.

5.1. Distancia de Riesgo de Memorización (DCR)

El cálculo del Riesgo de Memorización (DCR – *Distance to Closest Record*) se realizó sobre los tres modelos mediante búsqueda de vecino más cercano (*Ball Tree*) en el espacio euclidiano normalizado. La Tabla 8 consolida las distancias mínima, media y mediana para cada arquitectura.

Tabla 8: Resumen de Métricas DCR (*Distance to Closest Record*) por Modelo

Modelo	DCR Mín.	DCR Medio	DCR Mediano	Copia (< 0,01)
CTGAN	0.1196	3.1009	2.8844	0.00 %
TVAE	0.0444	2.2754	2.1221	0.00 %
TabDDPM	0.3938	2.8831	2.7611	0.00 %

El dictaminó que ningún registro sintético es una réplica exacta de un paciente real en ninguno de los tres modelos (riesgo de copia del 0,00 % en los tres casos). No obstante, la magnitud del DCR mínimo es reveladora: **TabDDPM** mantiene una distancia de seguridad mínima de 0,3938, frente a los 0,1196 de CTGAN y los apenas 0,0444 del TVAE. La mayor distancia mínima del modelo de difusión es una consecuencia directa de su proceso de generación: al muestrear desde ruido gaussiano puro y reconstruir iterativamente, la red de denoising introduce inherentemente variabilidad estocástica en cada paso, dificultando la convergencia hacia ningún punto exacto del espacio de entrenamiento.

Como expone el histograma de densidad empírica de la Figura 8, la frontera euclidiana mínima observada en el conjunto sintético emanado de la difusión asciende a **0.39**. La ausencia absoluta de tensores con $DCR = 0,0$ ratifica es-

tadísticamente la ausencia de memorización directa (*data leakage*) y anula el riesgo de “individualización” estipulado en las directivas del Artículo 29 europeo.




Figura 8: Distribución probabilística de las distancias euclidianas (DCR) frente al paciente biológico más cercano. La total ausencia de solapamiento en el origen (valor cero) descarta el fenómeno de memorización fotográfica.

5.2. Ataques Adversariales de Inferencia de Membresía (MIA)

Posteriormente, el modelo predictivo de caja blanca orquestado en modo de auditor se desplegó con la intención deliberada de inferir la pertenencia de pacientes concretos a la matriz original de entrenamiento hospitalario. Un resultado del 100 % supondría un incumplimiento del estándar de anonimización, posibilitando a un atacante vulnerar el anonimato del historial de admisiones de un ciudadano en riesgo de diabetes.

No obstante, el modelo clasificador del atacante no logró superar la capa estocástica del proceso inverso de difusión. El rendimiento del Ataque MIA sobre TabDDPM devolvió una curva ROC-AUC de **0.5033**. Al fijarse en la paridad absoluta con el 0,50, este valor certifica matemáticamente que las deducciones cibernéticas no rinden mejor que un oráculo tirando una moneda al aire (azar absoluto). Los tres modelos alcanzan valores de AUC estadísticamente indistinguibles del azar¹, lo que demuestra que ninguna de las arquitecturas

¹El aparente desajuste entre los valores de AUC cercanos al azar ($\approx 0,50$) y la precisión glo-

Tabla 9: Resultados de los Ataques de Inferencia de Membresía (MIA) por Modelo

Modelo	AUC Atacante	Accuracy Atacante	Privacidad
CTGAN	0.5028	0.3955	Excelente
TVAE	0.5022	0.6618	Excelente
TabDDPM	0.5033	0.4191	Excelente
<i>Ref. aleatoria</i>	<i>0.5000</i>	<i>0.5000</i>	—

evaluadas filtra información de membresía a través de sus datos sintéticos. Por transitividad, los datos sintéticos heredan legalmente el estatus de “anonimización irreversible”, posibilitando su circulación libre de sanciones, allanando el cumplimiento corporativo (Compliance) y reduciendo el prolongado *Time-to-Data* clínico.

6. Impacto Empresarial: Análisis del Time-to-Data

Más allá de los resultados técnicos, el valor estratégico del framework desarrollado reside en su capacidad para transformar el ciclo operativo de acceso a datos en entornos hospitalarios y de investigación clínica. Esta sección cuantifica el impacto económico y organizativo de la solución.

6.1. Reducción del Time-to-Data

En entornos hospitalarios y de investigación médica, el acceso a datos reales de pacientes (PII) está sujeto a un proceso burocrático multi-etapa que puede durar entre 9 y 18 semanas, como se detalla en la Tabla 10. Cada etapa implica

bal del atacante (p. ej., 66,18 % en TVAE) constituye un efecto del fuerte desbalanceo de clases de la auditoría (80 % de miembros de entrenamiento vs. 20 % de no miembros del holdout). En presencia de nula capacidad discriminadora ($AUC \approx 0,50$), la optimización del umbral por el índice de Youden sobre una curva ROC ruidosa genera un umbral que predice sesgadamente la clase mayoritaria (Miembros), produciendo una precisión de clasificación que converge hacia la proporción de dicha clase sin representar una capacidad real de filtración.

la intervención de actores institucionales distintos (comités de ética, delegados de protección de datos, equipos jurídicos) y puede bloquearse de forma indefinida en caso de requerimientos adicionales o correcciones.

Tabla 10: Comparativa del Time-to-Data: Proceso Tradicional vs. Framework Sintético

Etapas del proceso	Vía Tradicional (Real)	Vía Sintética (TabDDPM)
Solicitud al Comité de Ética	2–4 semanas	<i>No requerido</i>
Aprobación DPO (Data Protection Officer)	4–8 semanas	<i>No requerido</i>
Firma de acuerdos de confidencialidad (NDA/DPA)	2–4 semanas	<i>No requerido</i>
Anonimización manual / enmascaramiento	1–2 semanas	<i>No requerido</i>
Solicitud de acceso al entorno	—	≈ 1 día
Generación de dataset (TabDDPM)	—	10–30 minutos
Validación automática y descarga	—	≈ 1 hora
Time-to-Data Total	9–18 semanas (≈ 3–5 meses)	< 24 horas

La reducción cuantificada es del **98.4%** en el tiempo de acceso. Esta métrica tiene implicaciones directas sobre la cadencia de innovación: un equipo de ciencia de datos que necesite iterar sobre 10 hipótesis distintas de modelado predictivo a lo largo de un año de investigación reduciría su tiempo de espera acumulado de potencialmente 5 años de procesos burocráticos a menos de 10 días de generación sintética.

6.2. Viabilidad de Despliegue Corporativo y Escalabilidad MLOps

El framework ha sido diseñado desde su concepción para operar en entornos de producción corporativos, no solo como un prototipo académico. Su arquitectura de contenedores Docker garantiza la portabilidad hacia infraestructuras *cloud* (AWS, Azure, GCP) o *on-premise*. Los modelos generativos se almacenan en formatos estándar e interoperables: `tabddpm_model.pt` (compatible con TorchScript para despliegue de alto rendimiento en C++), y los modelos de línea base en formato `.pkl` de serialización estándar de Python.

Para la integración en flujos de trabajo MLOps a escala corporativa, se propone una arquitectura de microservicios en cuatro capas: una capa de **API REST** (FastAPI) que recibe solicitudes de generación con el número de registros y las restricciones demográficas deseadas; una capa de **orquestación asíncrona** (Celery/Redis) que gestiona la cola de tareas de generación en GPU; una capa de **almacenamiento seguro** (S3 cifrado o base de datos PostgreSQL) que almacena los datasets sintéticos validados listos para consumo; y una capa de **auditoría continua** que ejecuta automáticamente las pruebas DCR y MIA sobre cada lote generado antes de su publicación, garantizando el cumplimiento continuo del GDPR sin intervención humana.

El coste de entrenamiento inicial del motor TabDDPM ascendió a aproximadamente **48 horas de cómputo** sobre la GPU **AMD Radeon RX 9070**. Sin embargo, una vez entrenado el modelo, la generación de 99.340 registros (el volumen completo del dataset clínico) se realiza en **menos de 1 minuto**, con una complejidad de muestreo lineal $O(N)$ que permite escalar la generación a millones de registros mediante procesamiento por lotes (*batching*). Esta asimetría entre el coste de entrenamiento (invertido una sola vez) y el coste de inferencia (despreciable por solicitud) convierte al framework en una solución económicamente viable para su adopción institucional.

Capítulo 6: Conclusiones

La culminación de esta investigación marca el cierre de un ciclo intensivo de desarrollo algorítmico, evaluación matemática y auditoría legal. El presente capítulo consolida los hallazgos obtenidos, evaluando críticamente el grado de cumplimiento de los objetivos iniciales, analizando las limitaciones ineludibles de la arquitectura propuesta y trazando una hoja de ruta pragmática para la evolución futura del ecosistema de síntesis de datos clínicos.

7. Síntesis Comparativa de Resultados

Como punto de partida para la reflexión conclusiva, la Tabla 11 consolida en una única vista panorámica todas las métricas de evaluación obtenidas para los tres modelos generativos estudiados. Esta tabla permite visualizar, de forma simultánea, el equilibrio tri-dimensional entre fidelidad estadística, utilidad predictiva y robustez de privacidad que caracteriza a cada arquitectura.

1. Consecución de los Objetivos

El diseño fundacional de este Trabajo de Fin de Máster se vertebró sobre la consecución escalonada de cinco objetivos específicos, cuya materialización conjunta ha permitido cristalizar el objetivo general del proyecto.

- 1. Exploración del Estado del Arte y del Marco Normativo (Cumplido):** En el Capítulo 3 se analizó la evolución desde la privacidad estadística tradicional (k -anonimato, l -diversidad) hasta los marcos regulatorios actuales del GDPR y el Grupo de Trabajo del Artículo 29.

Tabla 11: Tabla Resumen Global de Rendimiento: Fidelidad, Utilidad y Privacidad

Métrica de Evaluación	CTGAN	TVAE	TabDDPM
<i>Fidelidad Estadística</i>			
WD Media ($\downarrow$ mejor)	0.762	0.602	0.397
Dif. Correlación MAE ($\downarrow$ mejor)	0.0675	0.0395	0.0122
<i>Utilidad Predictiva (TSTR con XGBoost)</i>			
F1-Score	0.5393	0.4486	0.5965
AUC-ROC	0.6143	0.6660	0.6567
Brecha vs. Baseline Real	-8.68 %	-24.04 %	+0.99 %
<i>Privacidad Empírica</i>			
DCR Mínimo ($\uparrow$ mejor)	0.1196	0.0444	0.3938
DCR Medio	3.1009	2.2754	2.8831
MIA AUC Atacante ($\approx 0,50$)	0.5028	0.5022	0.5033
Riesgo de Copia (DCR $< 0,01$)	0.00 %	0.00 %	0.00 %
<i>Impacto Operativo</i>			
Reducción Time-to-Data	98.4 % (de meses a < 24 horas)		

Se incorporó el experimento de reidentificación de Netflix (Narayanan & Shmatikov, 2008) como evidencia empírica de la insuficiencia de los enfoques clásicos. Asimismo, se describió el marco matemático de los modelos VAE, GAN y de difusión, fundamentando la elección del paradigma probabilístico.

2. Diseño e Implementación de la Arquitectura Generativa TabDDPM

(Cumplido): Se desarrolló una arquitectura de difusión basada en el modelo TabDDPM con $T = 1000$ pasos temporales y escalamiento de ruido lineal. La red de eliminación de ruido *DenoisingMLP*, con un tamaño de 1.097.483 parámetros entrenables, se diseñó para procesar la dimensión de 139 variables obtenida tras la codificación mixta. El pipeline se implementó en contenedores Docker utilizando la GPU nativa de PyTorch.

3. Evaluación de Fidelidad y Utilidad Predictiva (Cumplido):

Se aplicó el protocolo de evaluación TSTR (*Train on Synthetic, Test on Real*) empleando clasificadores XGBoost. El modelo TabDDPM alcanzó un F1-Score de **0.5965** en el conjunto de prueba real, superando en un +0,99 %

al baseline de referencia (0.5906). Esta configuración superó el desempeño de las líneas base CTGAN (que presentó una brecha del $-8,68\%$) y TVAE (con un $-24,04\%$), logrando reproducir la estructura multivariante con una diferencia de correlación MAE de apenas 0,0122.

4. Auditoría de Seguridad y Privacidad Empírica (Cumplido): Se evaluó la privacidad de los conjuntos de datos sintéticos mediante ataques simulados de inferencia de membresía (MIA), obteniendo un área bajo la curva ROC-AUC de 0.5033 (desempeño equivalente al azar). Adicionalmente, la auditoría de proximidad (DCR) registró una distancia mínima de seguridad de 0.3938, descartando el riesgo de memorización de registros reales.

5. Despliegue Operativo e Integración Clínica (Cumplido): Los resultados indican que el pipeline desarrollado es viable para la ingesta de registros médicos y la generación automatizada de conjuntos de datos sintéticos anónimos. Este enfoque optimiza el tiempo de acceso a datos clínicos, reduciéndolo de la escala habitual de 3 a 5 meses a menos de 24 horas, facilitando el inicio inmediato de tareas de investigación sin comprometer la privacidad del paciente.

La consecución de estos cinco hitos metodológicos valida el cumplimiento del Objetivo General del proyecto, consistente en desarrollar un framework de aprendizaje profundo para la síntesis de datos clínicos que optimice el tiempo de acceso a la información preservando la privacidad del paciente.

2. Consideraciones Finales y Reflexión Personal

El desarrollo de este Trabajo de Fin de Máster ha supuesto un reto técnico y metodológico significativo, obligando a abordar de forma práctica la brecha existente entre la teoría de los modelos generativos y su implementación en un entorno de producción real.

En el ámbito de la ingeniería de datos, el primer gran obstáculo radicó en

la depuración del conjunto de datos original (*Diabetes 130-US Hospitals*). La presencia de variables con un grado extremo de datos faltantes (como la columna `weight` con más del 96 % de nulos) y la elevada cardinalidad de los diagnósticos ICD-9 (con más de 700 códigos médicos distintos) exigieron el diseño de tuberías de limpieza personalizadas en Pandas. Agrupar manualmente estos códigos en 9 macro-categorías clínicas y depurar las inconsistencias de codificación (como los registros de género y pacientes fallecidos) consumió una cantidad considerable de horas, pero resultó crítico para estabilizar el entrenamiento de las redes.

En la dimensión de infraestructura y computación, la decisión metodológica de codificar la arquitectura TabDDPM desde cero en PyTorch (en lugar de utilizar librerías pre-construidas de alto nivel) introdujo dificultades añadidas. La configuración del entorno de aceleración por hardware (CUDA) y la gestión de la memoria de la GPU fueron procesos complejos. Durante las primeras iteraciones de entrenamiento de la red de eliminación de ruido (`DenoisingMLP`), el uso de tamaños de lote densos (como 4096) sobre la matriz estandarizada y codificada en One-Hot (139 dimensiones) provocó repetidos errores de falta de memoria (*Out-of-Memory*), lo que obligó a refactorizar el cargador de datos (*DataLoader*) y ajustar la dimensionalidad de las capas del modelo. Asimismo, el cálculo de la auditoría de privacidad empírica (DCR) mediante vecino más cercano sobre la totalidad del conjunto sintetizado (99,340 filas) supuso un cuello de botella computacional muy demandante para la CPU, resuelto mediante la optimización de los algoritmos de árbol de búsqueda (*Ball Tree*) utilizando paralelización.

En conclusión, este proyecto ha permitido consolidar un perfil técnico híbrido y de alta especialización, demostrando de forma empírica que el desarrollo de soluciones de Inteligencia Artificial aplicadas a entornos de alta sensibilidad exige no solo el dominio algorítmico profundo, sino también una comprensión rigurosa de las tuberías de ingeniería de datos, las restricciones físicas de la computación por hardware y los marcos regulatorios de privacidad.

3. Limitaciones del Estudio

A pesar de los resultados empíricos satisfactorios, la investigación adolece de limitaciones inherentes a la tecnología de difusión contemporánea y al alcance metodológico del presente trabajo que impiden catalogarla como un sistema libre de fricciones.

La carencia fundamental reside en el **coste computacional masivo y la latencia de inferencia**. Mientras que un modelo CTGAN (tras ser entrenado) requiere apenas de una única pasada por la red generadora (un *forward pass*) para sintetizar un nuevo registro paciente, el algoritmo TabDDPM requiere ejecutar su red densa T veces secuenciales en sentido inverso para cada lote de pacientes. Con la configuración de referencia ($T = 1000$), el tiempo de generación sintética es órdenes de magnitud más lento que el de una GAN equivalente, limitando su despliegue en escenarios que requieran síntesis de datos en estricto tiempo real (por ejemplo, transacciones de fraude de tarjetas en milisegundos o flujos de telemetría IoT de alta frecuencia).

Una segunda limitación significativa es la **dependencia de hardware especializado**. El entrenamiento del modelo TabDDPM durante 1.000 épocas requirió aproximadamente 48 horas sobre una GPU dedicada **AMD Radeon RX 9070**. En ausencia de aceleración por GPU, el tiempo de entrenamiento se incrementaría en un factor de 10x a 20x, haciendo inviable la experimentación iterativa sobre CPU. Esta dependencia implica que el despliegue del framework en instituciones con infraestructura de cómputo limitada requiere inversión adicional en *cloud computing* o en hardware especializado.

Adicionalmente, la red fue validada sobre un conjunto de datos monolítico plano (*single-table*). La realidad en los almacenes de datos hospitalarios modernos asume arquitecturas altamente normalizadas distribuidas en docenas de tablas relacionales jerárquicas (pacientes → admisiones → diagnósticos → medicaciones). El *framework* actual carece de la lógica ontológica para propagar automáticamente la generación de claves primarias y foráneas de forma referencialmente íntegra.

Finalmente, el protocolo TSTR empleado asume que la distribución del conjunto de entrenamiento y del conjunto de prueba es estacionaria (*i.i.d.*). En datasets con componente temporal relevante —como el seguimiento longitudinal de cohortes de pacientes donde los patrones de prescripción evolucionan a lo largo del tiempo— el modelo generativo entrenado en datos históricos puede no capturar adecuadamente el fenómeno de *concept drift*, generando datos sintéticos que reflejan la distribución pasada pero no la presente.

4. Prospectiva y Trabajo Futuro

Para mitigar las limitaciones expuestas y catapultar el valor comercial y científico del proyecto, la hoja de ruta de la infraestructura se expande hacia cuatro líneas de investigación venideras:

- **Muestreo Acelerado mediante Solvers Deterministas:** Se propone la implementación algorítmica de técnicas vanguardistas como Denoising Diffusion Implicit Models (DDIM) (Song et al., 2021) o DPM-Solvers. Estas alteraciones en la Ecuación Diferencial Ordinaria (ODE) del proceso inverso teóricamente permitirían a la red de *denoising* saltarse decenas de pasos temporales, acelerando la velocidad de inferencia en un factor de $10\times$ o $20\times$ sin sacrificar la fidelidad del TSTR. La adopción de DDIM reduciría el número de evaluaciones de la red de 1000 a 50–100, eliminando la principal limitación de latencia identificada.
- **Arquitecturas Relacionales (Multi-Table):** Desarrollar una red encapsuladora que procese el Grafo de Entidad-Relación de la base de datos SQL. La IA deberá comprender las multiplicidades lógicas (ej. un paciente biológico puede poseer infinitas admisiones, pero jamás dos fechas de nacimiento simultáneas) inyectando este condicionante estricto en la función de pérdida.
- **Integración de Privacidad Diferencial Formal (DP-SGD):** Una línea de investigación promisorio consiste en combinar el proceso de difusión con el mecanismo DP-SGD (*Differentially Private Stochastic Gradient Descent*), que inyecta ruido gaussiano calibrado sobre los gradien-

tes durante el entrenamiento. Mientras que el trabajo previo de Dwork (2006) demostró la incompatibilidad entre DP rígida y alta utilidad, las arquitecturas de difusión modernas, al generar implícitamente ruido estocástico en cada paso de muestreo, podrían ser intrínsecamente más compatibles con un presupuesto de privacidad ϵ moderado ($\epsilon \in [1, 5]$) sin la pérdida catastrófica de fidelidad observada en las GANs con DP.

- **Generación Transversal de Modalidades Mixtas y Benchmarking Multidominio:** Integrar capas de codificación basadas en *Transformers* (LLMs) capaces de ingerir y sintetizar las notas clínicas en texto libre redactadas por los doctores, fusionándolas indisolublemente con los parámetros tabulares discretos. Paralelamente, la validación del framework en dominios alternativos de alta sensibilidad —como la detección de fraude financiero o los sistemas de telemetría industrial IoT— permitiría certificar la generalidad del enfoque más allá del dominio clínico.

5. Consideraciones Finales y Reflexión Personal

Echar la vista atrás al trazado de este Trabajo de Fin de Máster invita a un profundo ejercicio de introspección sobre la madurez tecnológica alcanzada. A nivel competencial, el proyecto ha forjado un perfil técnico marcadamente híbrido. Desde la óptica de la Ingeniería de Datos y el *Deep Learning*, el dominio práctico de librerías de bajo nivel como PyTorch y la orquestación de GPU han mutado de la mera curiosidad académica a la destreza industrial.

Más allá del ámbito puramente codificador, el Máster ha infundido una visión holística sobre la Inteligencia Artificial: la comprensión innegociable de que los algoritmos no operan en un vacío hermético, sino que impactan en legislaciones civiles y éticas sociales. La inmersión en la dogmática del GDPR y la capacidad de argumentar matemáticamente (vía Privacidad Empírica) la licitud de un sistema IA demuestran una evolución desde un programador estándar hacia un perfil de Arquitecto de IA Corporativa responsable.

Resultaría injusto no expresar un sincero agradecimiento al equipo docente del

Máster, cuya perseverancia ha elevado sistemáticamente mis estándares académicos, y de manera particular, a mi tutor y círculo cercano, cuya paciencia incombustible brindó el soporte necesario para superar las dificultades técnicas y los errores de compilación durante el desarrollo algorítmico.

Para concluir, no puedo terminar este proyecto sin reflejar mi deseo de que las restricciones excesivas de ciberseguridad no actúen como un obstáculo para el avance biomédico. Confío en que, en el futuro cercano, las arquitecturas de síntesis de datos de código abierto terminen por minimizar el impacto de los silos de información privados, logrando que el conocimiento necesario para curar patologías críticas, como la diabetes, fluya libremente entre los investigadores de todo el globo terráqueo. Por mi parte, espero sinceramente que esta humilde pero rigurosa contribución tecnológica suponga un eslabón firme hacia esa utopía.

Bibliografía

- Article 29 Data Protection Working Party. (2014). *Opinion 05/2014 on Anonymisation Techniques* (inf. téc. N.º 0829/14/EN – WP 216). European Commission. https://ec.europa.eu/justice/article-29/documentation/opinion-recommendation/files/2014/wp216_en.pdf
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. <https://doi.org/10.1145/2939672.2939785>
- Choi, E., Biswal, S., Malin, B., Duke, J., Stewart, W. F., & Sun, J. (2017). Generating Multi-label Discrete Patient Records using Generative Adversarial Networks. *Proceedings of the 2nd Machine Learning for Healthcare Conference*, 68, 286-305. <https://arxiv.org/abs/1703.06490>
- DataCebo, Inc. (2023). *SDV: Synthetic Data Vault* (Ver. 1.x). <https://sdv.dev>
- Dwork, C. (2006). Differential Privacy. *Automata, Languages and Programming: 33rd International Colloquium, ICALP 2006*, 4052, 1-12. https://doi.org/10.1007/11787006_1
- El Emam, K., Mosquera, L., & Jonker, E. (2020). *Practical Synthetic Data Generation: Balancing Privacy and the Broad Availability of Data*. O'Reilly Media.
- Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., & Bengio, Y. (2014). Generative Adversarial Nets. *Advances in Neural Information Processing Systems*, 27. <https://arxiv.org/abs/1406.2661>

- Ho, J., Jain, A., & Abbeel, P. (2020). Denoising Diffusion Probabilistic Models. *Advances in Neural Information Processing Systems*, 33, 6840-6851. <https://arxiv.org/abs/2006.11239>
- Kingma, D. P., & Welling, M. (2014). Auto-Encoding Variational Bayes. *arXiv preprint arXiv:1312.6114*. <https://arxiv.org/abs/1312.6114>
- Kotelnikov, A., Baranchuk, D., Rubachev, I., & Babenko, A. (2023). TabDDPM: Modelling Tabular Data with Diffusion Models. *Proceedings of the 40th International Conference on Machine Learning*, 202, 17564-17579. <https://arxiv.org/abs/2209.15421>
- Machanavajjhala, A., Kifer, D., Gehrke, J., & Venkitasubramaniam, M. (2007). l-Diversity: Privacy Beyond k-Anonymity. *ACM Transactions on Knowledge Discovery from Data*, 1(1), 3. <https://doi.org/10.1145/1217299.1217302>
- Narayanan, A., & Shmatikov, V. (2008). Robust De-anonymization of Large Sparse Datasets. *2008 IEEE Symposium on Security and Privacy (SP)*, 111-125. <https://doi.org/10.1109/SP.2008.33>
- Nichol, A. Q., & Dhariwal, P. (2021). Improved Denoising Diffusion Probabilistic Models. *Proceedings of the 38th International Conference on Machine Learning*, 139, 8162-8171. <https://arxiv.org/abs/2102.09672>
- Parlamento Europeo and Consejo de la Unión Europea. (2016). Reglamento (UE) 2016/679 del Parlamento Europeo y del Consejo, de 27 de abril de 2016, relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales y a la libre circulación de estos datos [Diario Oficial de la Unión Europea, L 119, pp. 1–88]. <https://eur-lex.europa.eu/legal-content/ES/TXT/?uri=CELEX:32016R0679>
- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Köpf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S., Steiner, B., Fang, L.,

- ... Chintala, S. (2019). PyTorch: An Imperative Style, High-Performance Deep Learning Library. *Advances in Neural Information Processing Systems*, 32. <https://arxiv.org/abs/1912.01703>
- ResearchGate. (2019). The general architecture of GAN. Consultado el 27 de mayo de 2026, desde https://www.researchgate.net/figure/The-general-architecture-of-GAN_fig5_338050169
- ResearchGate. (2024). The forward and backward processes of the diffusion model. Consultado el 27 de mayo de 2026, desde https://www.researchgate.net/figure/The-forward-and-backward-processes-of-the-diffusion-model-The-credit-of-the-used-images_fig1_382128283
- Shende, R. (2023). *Autoencoders, Variational Autoencoders (VAE) and β -VAE*. Consultado el 27 de mayo de 2026, desde <https://medium.com/@rushikesh.shende/autoencoders-variational-autoencoders-vae-and-%CE%B2-vae-ceba9998773d>
- Shokri, R., Stronati, M., Song, C., & Shmatikov, V. (2017). Membership Inference Attacks Against Machine Learning Models. *2017 IEEE Symposium on Security and Privacy (SP)*, 3-18. <https://doi.org/10.1109/SP.2017.41>
- Song, J., Meng, C., & Ermon, S. (2021). Denoising Diffusion Implicit Models. *International Conference on Learning Representations*. <https://arxiv.org/abs/2010.02502>
- Stadler, T., Oprisanu, B., & Troncoso, C. (2022). Synthetic Data – Anonymisation Groundhog Day. *31st USENIX Security Symposium (USENIX Security 22)*, 1451-1468. <https://www.usenix.org/conference/usenixsecurity22/presentation/stadler>
- Strack, B., DeShazo, J. P., Gennings, C., Olmo, J. L., Ventura, S., Cios, K. J., & Clore, J. N. (2014). Impact of HbA1c Measurement on Hospital Readmission Rates: Analysis of 70,000 Clinical Database Patient Records.

BioMed Research International, 2014, 781670. <https://doi.org/10.1155/2014/781670>

Sweeney, L. (2002). k-Anonymity: A Model for Protecting Privacy. *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, 10(5), 557-570. <https://doi.org/10.1142/S0218488502001648>

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser,., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, 30. <https://arxiv.org/abs/1706.03762>

Villani, C. (2008). Optimal Transport: Old and New. *Grundlehren der Mathematischen Wissenschaften*, 338. <https://doi.org/10.1007/978-3-540-71050-9>

Xu, L., Skoularidou, M., Cuesta-Infante, A., & Veeramachaneni, K. (2019). Modeling Tabular Data using Conditional GAN. *Advances in Neural Information Processing Systems*, 32. <https://arxiv.org/abs/1907.00503>

Zhao, Z., Kunar, A., Birke, R., & Chen, L. Y. (2021). CTAB-GAN: Effective Table Data Synthesizing. *Proceedings of the 13th Asian Conference on Machine Learning*, 157, 97-112. <https://arxiv.org/abs/2102.08369>

Anexos

La presente sección suplementaria documenta las especificaciones de bajo nivel e hiperparámetros exactos de instanciación de los modelos. Asimismo, se proporciona el enlace al repositorio público donde se encuentra disponible el código fuente completo del proyecto, garantizando la reproducibilidad íntegra del Trabajo de Fin de Máster.

A.1. Diccionario de Hiperparámetros de Entrenamiento

Para garantizar una evaluación rigurosa y adaptada a la naturaleza de cada paradigma generativo, las líneas base (CTGAN y TVAE) fueron entrenadas utilizando hiperparámetros estandarizados de la literatura, mientras que el modelo propuesto (TabDDPM) se parametrizó bajo su régimen óptimo de convergencia, adaptado a la dinámica del proceso inverso de difusión de Markov.

A.2. Repositorio de Código Fuente

El código fuente completo implementado para la limpieza del conjunto de datos, el preprocesamiento, el entrenamiento de los modelos generativos (CTGAN, TVAE y TabDDPM) y la ejecución de las auditorías de utilidad y privacidad (DCR y MIA) está alojado en el repositorio público de GitHub.

Se puede acceder al repositorio a través del siguiente enlace:

<https://github.com/marquito3012/TFM>

Tabla 12: Repertorio de Hiperparámetros Arquitectónicos

Modelo	Parámetro Físico	Valor Instanciado
Global (Baselines)	Épocas de Entrenamiento (<i>Epochs</i>)	300
Global (Baselines)	Tamaño del Lote (<i>Batch Size</i>)	500
Global (Baselines)	Optimizador de Gradiente	Adam
Global (Baselines)	Tasa de Aprendizaje (<i>Learning Rate</i>)	2×10^{-4}
CTGAN	Dimensión del Ruido Latente	128
CTGAN	Dimensiones del Generador MLP	(256, 256)
CTGAN	Dimensiones del Discriminador MLP	(256, 256)
TVAE	Dimensión del Espacio Latente (<i>Bottleneck</i>)	128
TVAE	Dimensiones del Encoder	(128, 128)
TVAE	Dimensiones del Decoder	(128, 128)
TabDDPM	Pasos de Difusión (<i>T</i>)	1000
TabDDPM	Estrategia del Ruido (<i>Noise Schedule</i>)	Lineal
TabDDPM	Arquitectura de la Red Denoising (MLP)	3 ResBlocks (512 c/u)
TabDDPM	Épocas de Entrenamiento (<i>Epochs</i>)	1000
TabDDPM	Tamaño del Lote (<i>Batch Size</i>)	4096
TabDDPM	Tasa de Aprendizaje (<i>Learning Rate</i>)	1×10^{-3}
TabDDPM	Decaimiento de Pesos (<i>Weight Decay</i>)	1×10^{-4}