UAX Universidad Alfonso X el Sabio

Trabajo Fin de Master (TFM) PROPUESTA

Máster Universitario en Inteligencia Artificial

Fecha Propuesta:

17 febrero 2026

Nombre y Apellido: Marco Fernández Pérez

E-mail: marcfepe@myuax.com

DNI: 72106202Y

Detalles TFM

Título

Generación de Datos Sintéticos para Sectores con Datos Sensibles

¿Profesor Candidato?

Leonardo Dulcetti

1. Planteamiento del problema (tarea sobre el que versará el TFM):

En sectores altamente regulados (Finanzas/Salud), el acceso a datos de calidad para entrenar modelos de IA se ve limitado por normativas de privacidad como el GDPR. Las técnicas de anonimización tradicionales a menudo sufren un dilema: o protegen la privacidad destruyendo la utilidad estadística del dato, o mantienen la utilidad, pero dejan al usuario vulnerable a ataques de re-identificación. El problema central de este TFM es desarrollar y evaluar un framework de IA Generativa capaz de producir datos tabulares sintéticos que preserven la utilidad para modelos predictivos mientras garantizan niveles de privacidad matemáticamente robustos.

2. Objetivos (unas 500 palabras, procure ser concreto):

El objetivo general de este proyecto es investigar, implementar y validar un framework avanzado de generación de datos sintéticos (SDG) aplicado a entornos con alta sensibilidad de privacidad (como el financiero o sanitario). El propósito es demostrar que es posible generar datasets artificiales que mantengan la utilidad estadística necesaria para el

© Universidad Alfonso X el Sabio

entrenamiento de modelos de Machine Learning, garantizando al mismo tiempo el anonimato de los sujetos originales y el cumplimiento de marcos normativos como el GDPR.

Para alcanzar esta meta, se proponen los siguientes objetivos:

A. Investigación y Selección de Arquitecturas Generativsas

El primer paso consiste en realizar un análisis comparativo y crítico de las arquitecturas de IA Generativa diseñadas para datos tabulares heterogéneos. Se profundizará en modelos como CTGAN (Conditional Tabular GAN), TVAE (Tabular Variational Autoencoder) y los recientes Tabular Diffusion Models. El objetivo es identificar qué arquitectura gestiona mejor los problemas comunes en bases de datos reales: variables categóricas de alta cardinalidad, distribuciones multimodales y desequilibrio de clases (imbalance).

B. Implementación y Optimización del Motor de Generación

Se desarrollará un pipeline robusto capaz de ingerir datos sensibles brutos y transformarlos en un espacio latente para su generación. Esto implica el diseño de estrategias de pre-procesamiento específicas, como el uso de Reversible Data Transforms (RDT) para manejar columnas no gaussianas. Un hito técnico clave será la optimización de los hiperparámetros del generador para evitar el *overfitting* (que comprometería la privacidad) y el *mode collapse* (que comprometería la diversidad del dato).

C. Evaluación de la Fidelidad Estadística y Correlacional

No basta con que los datos “parezcan” reales; deben comportarse como tales. Se implementará un módulo de evaluación que compare las distribuciones marginales (univariantes) y, lo más importante, las interdependencias multivariantes. Se utilizarán métricas de distancia como la distancia de Wasserstein y comparativas de matrices de correlación de Pearson/Spearman para asegurar que las reglas de negocio implícitas en los datos originales (ej. La relación entre edad y sasldo bancario) se conservan íntegras en el set sintético.

D. Validación de la Utilidad para Machine Learning (TSTR)

El objetivo orientado a producto es validad si un modelo de IA entrenando exclusivamente con datos sintéticos puede ser desplegado en producción sobre datos reales. Para ello, se aplicará la metodología TSTR (Train on Synthetic, Test on Real). Se comparará el rendimiento (métrica F1, AUC y Accuracy) de clasificadores entrenados con datos reales frente a los entrenados con datos sintéticos. El éxito se define al lograr una brecha de rendimiento inferior al 5%.

E. Cuantificación de la Privacidad y Resiliencia ante Ataques

Se establecerá un protocolo de pruebas de estrés para medir el riesgo de identificación. Se implementarán métricas de proximidad como DCR (Distance to Closest Record) para asegurar que ningún registro sintético es una copia exacta de uno real. Asimismo, se simularán Ataques de Inferencia de Membresía (MIA) para evaluar si un atacante externo podría determinar si un individuo específico formó parte del dataset de entrenamiento, garantizando así un nivel de privacidad robusto ante auditorías.

© Universidad Alfonso X el Sabio

F. Análisis de Impacto y Viabilidad Empresarial

Finalmente, el proyecto busca cuantificar el valor de negocio. Se realizará un análisis del "Time-to-Data": cuánto tiempo se ahorra al usar datos sintéticos frente a los procesos burocráticos de acceso a datos reales. Se evaluará la escalabilidad de la solución para su integración en plataformas de MLOps, permitiendo que equipos de Data Science innoven sin necesidad de manejar datos PII (Personally Identifiable Information).

3. Metodología y Procedimiento:

Se seguirá una metodología experimental basada en el ciclo de vida de proyectos de ciencia de datos:

1. Adquisición de Datos: Selección de un dataset público de alta sensibilidad.
2. Pre-procesamiento avanzado: Tratamiento de valores nulos, codificación de variables categóricas con alta cardinalidad y normalización de variables continuas segadas.
3. Entrenamiento del Modelo: Se propone el uso de CTGAN (Conditional Tabular GAN) o TVAE (Tabular VAE). Se realizarán experimentos variando hiperparámetros y funciones de pérdida.
4. Validación Cruzada de Utilidad: Se utilizará el enfoque "Train on Synthetic, Test on Real" (TSTR)
5. Cuantificación de Privacidad: Uso de métricas como el *Distance to Closest Record* (DCR) para verificar que no hay replicación exacta de los datos de entrenamiento.

4. Indice de contenidos tentativo del trabajo:

1. Introducción (Motivación, contexto legal y objetivos).
2. Estado del Arte (De la anonimización clásica a la IA Generativa: GANs, VAEs y Diffusion Models).
3. Marco Teórico (Funcionamiento de los modelos generativos tabulares y métricas de privacidad).
4. Metodología y Entorno Experimental (Stack tecnológico: TensorFlow, SDV Library, descripción del dataset).
5. Implementación del Modelo Generativo (Arquitectura propuesta y proceso de entrenamiento).
6. Evaluación de Resultados:
    a. Análisis de Fidelidad Estadística.
    b. Evaluación de Utilitdad en Tareas de ML.
    c. Informe de Riesgos de Privacidad.

© Universidad Alfonso X el Sabio

7. Discusión e Impacto Empresarial (Análisis de costes y aplicabilidad en producción).
8. Conclusiones y Trabajo Futuro.

5. Bibliografía (Señale al menos tres referencias bibliográficas relacionadas con el tema propuesto):

El Emam, K., Mosquera, L., & Hoptroff, R. (2020). *Practical Synthetic Data Generation: Cannibalizing the Data Science Stack.* Sebastopol, CA: O'Reilly Media.

Stadler, T., Oneto, L., & Troncoso, C. (2022). *Synthetic Data – Anonymization Groundhog Day?* Boston, MA: USENIX Association.

Xu, L., Skoularidou, M., Cuesta-Infante, A., & Veeramachaneni, K. (2019). *Modeling Tabular Data using Conditional GAN.* Vancouver: Curran Associates, Inc.

© Universidad Alfonso X el Sabio

UAX Universidad Alfonso X el Sabio

UAX.COM